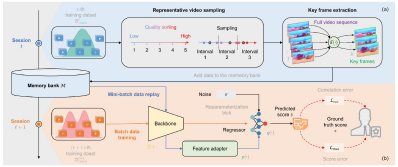
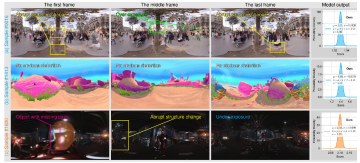
Adaptive Score Alignment Learning for Continual Perceptual Quality Assessment of 360-Degree Videos in Virtual Reality

Kanglei Zhou, Zikai Hao, Liyuan Wang, Xiaohui Liang (2025)







どんなもの？

360度動画の知覚品質を予測する**ASAL**を提案
新しい動画への適応と、過去の知識の保持を目指す

どうやって有効だと検証した？

実環境の360度動画で一括／逐次学習を比較
人の評価との対応・予測誤差で**全体性能が最良**

先行研究の課題は？

人の評価との対応と予測値の精度
変化する動画への適応と保存量の制約

継続学習の狙いは？

新しい動画に適応し、過去の知識を保持
少数のフレームを保存して再利用する

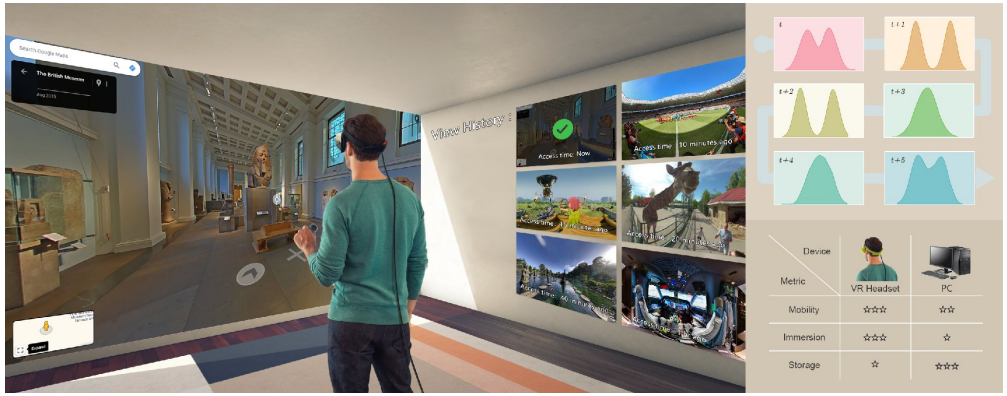
技術や手法のキモはどこ？

確率的なスコア回帰と2種類の損失
過去動画の少数画像を再利用する学習

今後の展望は？

データ拡張と動的なメモリ管理
利用者からのリアルタイムなフィードバック

研究背景：360-degree Video Quality Assessment (VQA)



Virtual Reality (VR)の360度動画では、ヘッドセットで全方向のシーンを探索できる
stitching errors：複数の映像をつなぐ際に、つなぎ目がずれること
compression artifacts：データ圧縮で生じるブロック状の乱れやぼけなど
ぼけやこれらの歪みは没入体験を損ね、身体的な不快感を引き起こす場合もある

利用者が感じる映像の品質を評価し、没入体験を保つことが重要

予測する対象：動画の知覚品質スコア

入力

フレーム：動画を構成する1枚の静止画像
入力は、フレーム数T、幅W、高さH、RGBの3チャネルからなる360度動画

予測するもの

没入環境で利用者が知覚する動画品質を、一つのスコアとして予測

学習の対象

予測スコアと正解スコアを比較する損失を最小化する

ニューラルネットワークで、360度動画の知覚品質スコアを予測する

正解スコアと予測スコア

対象	役割
入力動画	360度動画
正解スコア	人間の主観スコア
予測スコア	モデルの品質予測値

人間の主観スコアに予測を整合させる

損失は、予測値と正解値の違いを定量化する

予測モデルの重みを、損失が小さくなるよう学習する

先行研究と研究目的

従来手法	論文が指摘する課題	本研究の対応
VQA・VR-VQA	相関を重視し、予測スコアの 絶対誤差が残る	相関損失と誤差損失を併用
静的データセット	歪みの多様性が限られ 新しい内容へ適応しにくい	継続学習で 分布の変化に適応
Compressed Replay	動画の再構成には 追加の計算負荷が生じる	Keyframeを保存し 画像ではなく特徴空間で再構成

研究目的

人間の主観評価との整合と予測精度を高め、変化するVR動画へ継続的に適応する

Continual Learning (CL) の問題設定

Task（タスク）：追加学習のひと区切り

新しい動画データ集合が与えられるたびに学習し、その各段階をタスクと呼ぶ

Catastrophic Forgetting

新しいデータの学習で、以前に獲得した知識を失うことがある

保存容量・計算資源の制約

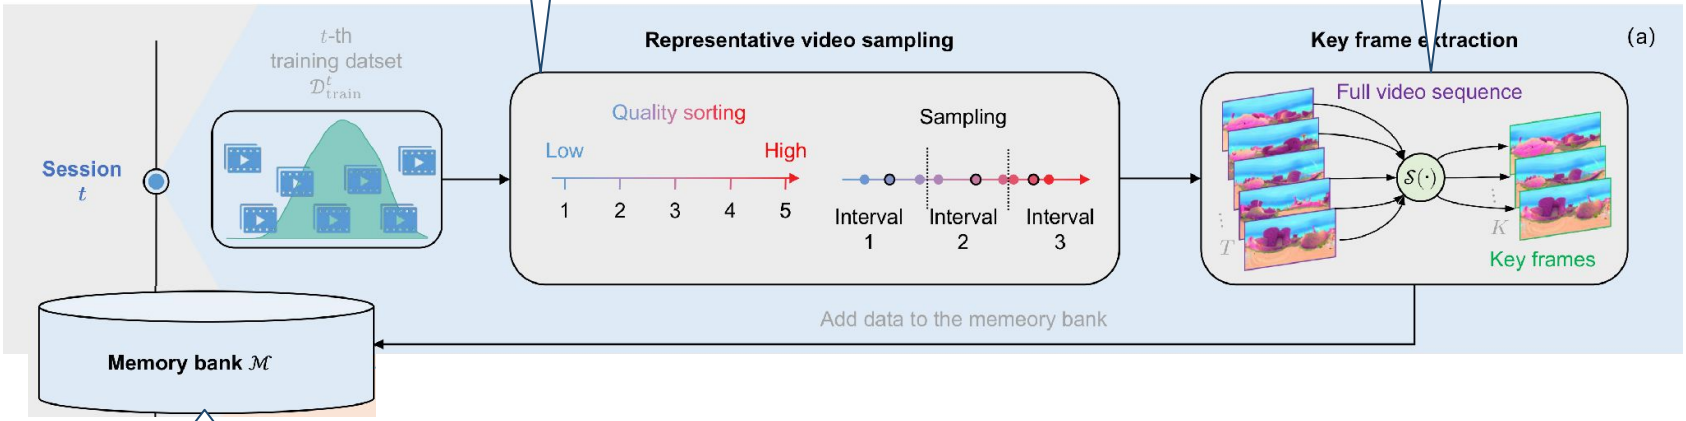
VR機器では、学習に使える保存容量と計算資源が限られる

新しいデータへの適応と、過去のデータに関する知識の保持を両立する

提案手法：学習フロー① タスク終了時の保存

① 代表動画を選ぶ
品質スコア順に並べ、
順位の間隔をそろえて抽出

② Keyframeを抽出
各動画から代表的な静止画像
（Keyframe）を少数選ぶ

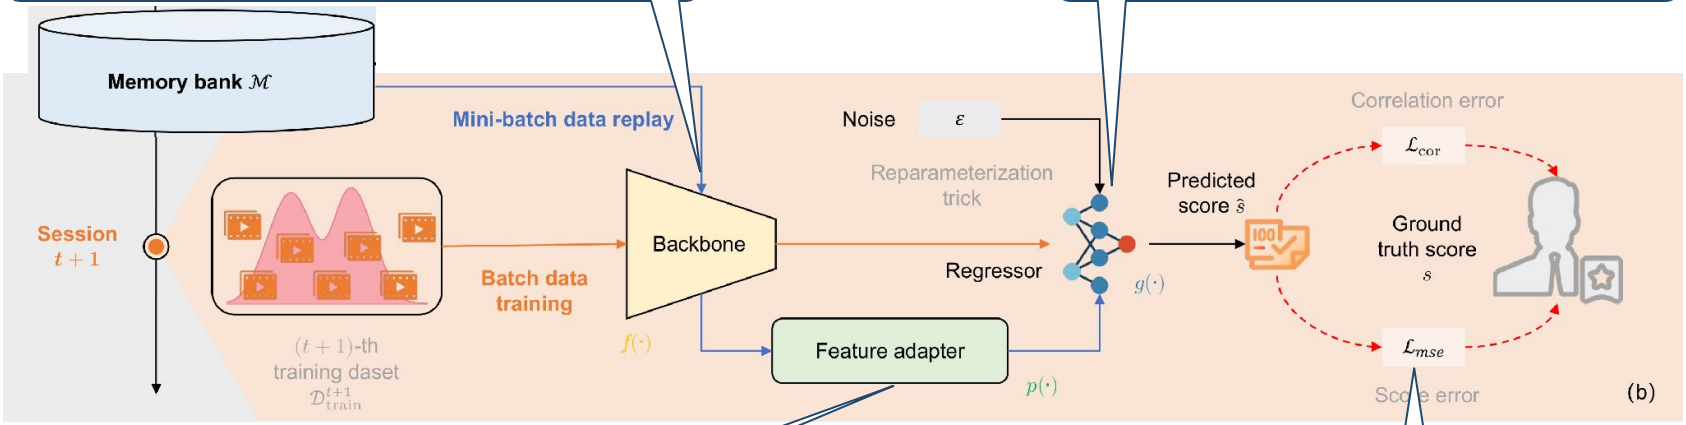


③ メモリバンクに保存
フレーム画像と元動画の正解スコアを保持

提案手法：学習フロー② 次のタスクでの学習

① 現在データとReplay
現在の動画と保存した動画から
Backboneで特徴を抽出する

③ 品質スコアを予測
Regressorで動画の特徴から
品質スコアを計算する



② 過去データの特徴を再構成
Feature Adapterで
動画全体の特徴に近づける

④ 二つの損失で学習
人の評価との相関と
スコアの誤差を扱う

提案手法：特徴抽出とスコア回帰

$$\mathbf{x} \in \mathbb{R}^{T \times W \times H \times 3} \xrightarrow{f} \mathbf{h} \in \mathbb{R}^{T \times D} \xrightarrow{g} \hat{s}$$

$$\tilde{\mathbf{x}} \in \mathbb{R}^{K \times W \times H \times 3} \xrightarrow{f} \tilde{\mathbf{h}} \in \mathbb{R}^{K \times D}, \quad K < T$$

Backbone f：各フレームからD次元のFeature (特徴)を抽出

Regressor g：動画の特徴から品質スコアを予測

Tは通常のフレーム数、Kは保存したフレーム数。Dは共通

提案手法：スコア予測に必要な二つの観点

主観スコアを予測できても、その予測が良いかどうかを確かめる必要がある
本研究では、人の評価との対応と、予測値のずれを分けて扱う

観点	確認すること	例
品質の対応	主観スコアが高い動画ほど、予測も高いか	順序・関係
点数の近さ	予測スコアと主観スコアのずれが小さいか	値の差

説明用の例：全ての動画を1点高く予測

動画	A	B	C
正解スコア	1	2	3
予測スコア	2	3	4

評価指標：PLCCとSRCC

Pearson Linear Correlation Coefficient (PLCC)
Spearman’s Rank Correlation Coefficient (SRCC)

指標	比較する対象	範囲
PLCC	主観スコアと予測値の線形な対応	−1〜1
SRCC	主観スコアの順位と予測順位の対応	−1〜1

学習・評価での使い分け

指標	学習の損失	性能評価	着目する対応
PLCC	使用	使用	値の線形な対応
SRCC	直接は使わない	使用	順位の対応

提案手法：スコア分布とReparameterization

$$s \mid \mathbf{h} \sim \mathcal{N}\left(\mu(\mathbf{h}), \sigma^2(\mathbf{h})\right)$$

$$\hat{s} = \mu(\mathbf{h}) + \sigma(\mathbf{h})\epsilon, \qquad \epsilon \sim \mathcal{N}(0, 1)$$

特徴 hから、スコア分布の平均μと標準偏差σを予測

εは標準正規乱数。σ^2ではなく標準偏差σを掛ける

再パラメータ化：乱数を使う計算を、誤差逆伝搬できる形に書き換える

提案手法：二つの損失を組み合わせた学習

$$\mathcal{L}_{\text{com}} = \underbrace{1 - \text{PLCC}}_{\mathcal{L}_{\text{cor}}} + \lambda \underbrace{\frac{1}{2N} \sum_{i=1}^{N} (s_i - \hat{s}_i)^2}_{\mathcal{L}_{\text{mse}}}$$

損失	最適化する対象
Correlation Loss: 1−PLCC	主観スコアと予測値の線形相関を高める
Mean Squared Error (MSE) Loss	予測値そのものを主観スコアに近づける

λは二つの損失の相対的な重みを調整する

提案手法：Adaptive Memory Replay

代表動画の選択

品質順に並べ、順位の間隔をそろえて代表動画を選ぶ

Keyframeの保存

各動画から少数のフレーム画像を選び、元動画の正解スコアと保存する

Replay

現在のBackboneで、保存画像から特徴を再抽出する
元動画の正解スコアで損失を計算し、モデルを再学習する

提案手法：Feature Adapter

$$\tilde{\mathbf{h}} \in \mathbb{R}^{K \times D} \xrightarrow{p} \hat{\mathbf{h}} \in \mathbb{R}^{T \times D} \xrightarrow{g} \hat{s}$$

K フレーム分の特徴から、T フレーム分の特徴を推定

入力と出力で時間方向の長さが変わる

再構成する対象は特徴。元の画像列や再生可能な動画ではない

提案手法：全体の目的関数と特徴の再構成損失

$$\min_{\Theta} \ \mathcal{L}_{\text{com}}^{\text{new}} + \alpha \mathcal{L}_{\text{com}}^{\text{old}} + \beta \mathcal{L}_{\text{reg}}$$

損失の項	役割
新規データの損失	現在の動画の品質予測を学習
Replayデータの損失	過去の動画の品質予測を維持
Feature Regularization	現在データでFeature Adapterの再構成を学習

$$\mathcal{L}_{\text{reg}} = \sum_{i} \|\mathbf{h}_i^t - \hat{\mathbf{h}}_i^t\|_2, \qquad \hat{\mathbf{h}}_i^t = p\big(\phi(\mathbf{h}_i^t)\big)$$

VR Video Quality in the Wild (VRVQW)

カテゴリ	動画数
都市景観	142
自然景観	84
ショー	87
スポーツ	23
Computer Graphics (CG)	34
その他	132

ユーザー生成360度動画 502本

実環境由来の複合的な画質劣化を含む

ASALでは6 カテゴリのラベルを手作業で追加

各動画に視聴時間2通り × 開始方向2通り

映像形式：Equirectangular Projection (ERP)

Joint Training (JT) とContinual Learning

設定	学習データ
Joint Training (JT)	対象カテゴリの学習データをまとめて利用
Continual Learning (CL)	その他の学習データで事前学習 その後、残り5 カテゴリを順に学習

1 カテゴリ = 1 タスク。出力は常に品質スコア

元動画の派生版を含むサンプル数を、タスク間でそろえる方針

各タスクの20%をテスト用に分離し、学習側は最大50サンプル

テストデータは重み更新に使わず、全テストサンプルを評価に残す

学習条件と全体評価の計算方法

項目	設定・定義
Optimizer	Adam, learning rate 0.0001, weight decay 0.0005
学習	15 エポック／タスク
Batch Size	新規データ $b_1 = 3$、Replayデータ $b_2 = 2$
損失の重み	$\alpha = \beta = 1$。λは感度分析で検討
全体指標	各セッションのサンプルを集約して計算

評価指標：Relative L2 Error (RL2E)

$$\mathrm{RL2E} = \frac{1}{N} \sum_{i}^{N} \left(\frac{|s_i - \hat{s}_i|}{s_{\max} - s_{\min}} \right)^2 .$$

スコア範囲で正規化した誤差を二乗し、平均する

0が最良。小さいほど予測値が正解に近い

Joint Training：全体の比較結果

手法	PLCC ↑	SRCC ↑	RL2E ↓
HGCN	0.4106	0.4179	0.0392
ERP-VQA	0.7530	0.7510	0.8380
Wen et al.	0.7610	0.7570	0.9797
ASAL	**0.7979**	**0.7932**	**0.0193**

表 1の報告値では、ASALは高い相関と小さいスコアの誤差を示す

Joint Training：Ablation Study

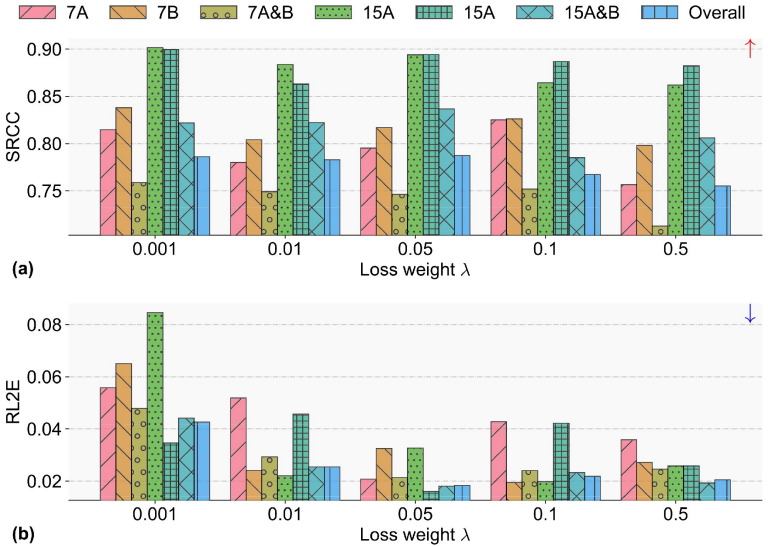
条件	PLCC ↑	SRCC ↑	RL2E ↓
ASAL	**0.7979**	**0.7932**	**0.0193**
MSE Lossなし	0.7839	0.7898	1.2995
Correlation Lossなし	0.7714	0.7707	0.0185
Reparameterizationなし	0.7759	0.7714	**0.0181**

Reparameterizationを除いた場合のRL2E

本文：「0.0210 → 0.0181に増加」

表2：0.0193 → 0.0181に減少（誤差は改善）

損失の重みλの影響



検討したλは0.001、0.01、0.05、0.1、0.5
著者はλ＝0.05を採用。探索した範囲での選択

λを変えたときの相関と誤差を、別々に確認する

Continual Learning：全体の比較結果

Synaptic Intelligence (SI) / Dark Experience Replay++ (DER++)
Manifold-aligned Graph Regularization (MAGR)

手法	SRCCove ↑	RL2Eove ↓
Sequential Fine-tuning (Seq FT)	0.4567	0.0712
SI	0.6227	0.0328
DER++	0.5825	0.0359
MAGR	0.5089	0.0394
ASAL	**0.7148**	**0.0267**

継続学習手法の比較では、ASALが全体の相関・誤差で最良

Continual Learning：Ablation Study

条件	SRCCove ↑	RL2Eove ↓
ASAL	**0.7148**	**0.0267**
Keyframe抽出なし	0.7062	0.0302
Feature Adapterなし	0.6846	0.0309
Lregなし	0.7105	0.0296
Base Pre-trainingなし	0.4805	0.0421

「その他」による事前学習の効果が、この比較では大きい

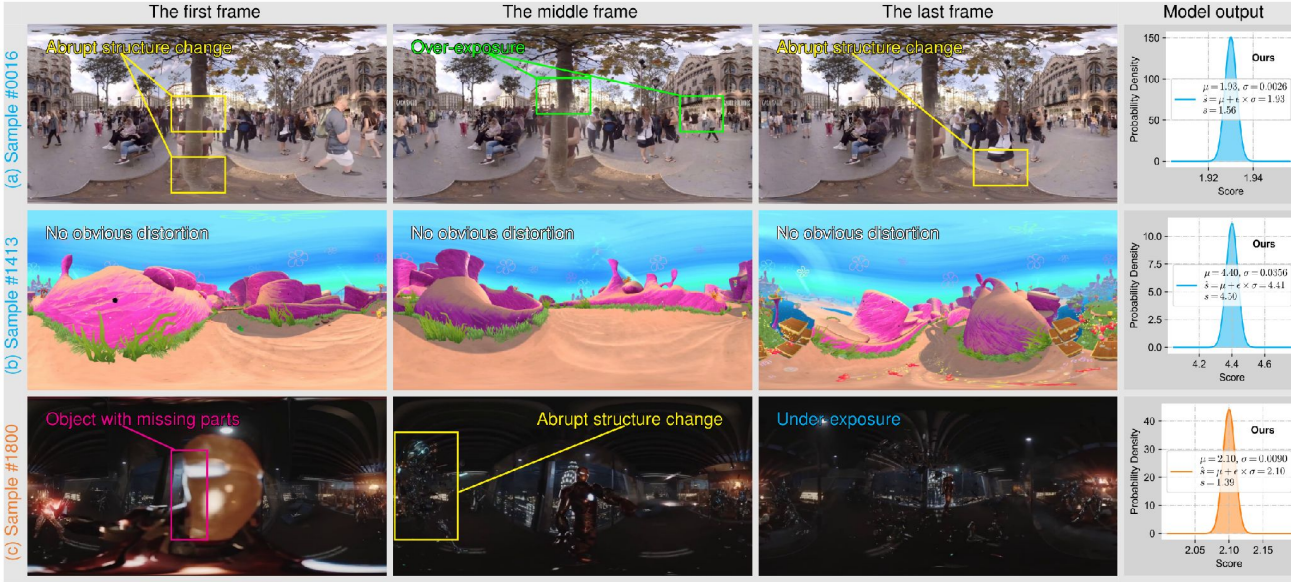
学習時間と保存容量

Slow Learner with Classifier Alignment (SLCA)

手法	学習時間 (h)	保存容量 (MB)	SRCCove
DER++	0.6167	262.50	0.5825
SLCA	0.2667	0.63	0.3290
MAGR	0.5167	0.01	0.5089
ASAL	**0.3000**	**112.50**	**0.7148**

ASALはDER++より保存量を削減。ただし最小保存量の手法ではない

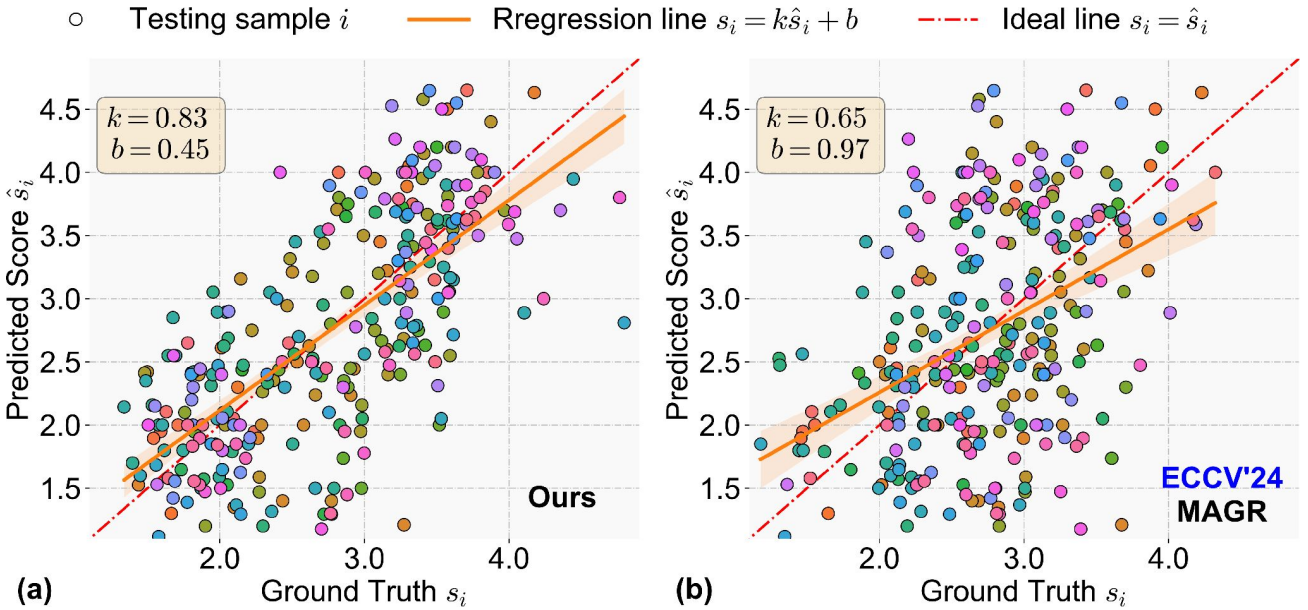
動画ごとの予測例



#0016：正解1.56、ASAL 1.93、比較手法3.93（本文値）
#1800：正解1.39に対し、ASALでも2.10と誤差が残る

露出や形の不連続など、複数の歪みを含む事例を示す

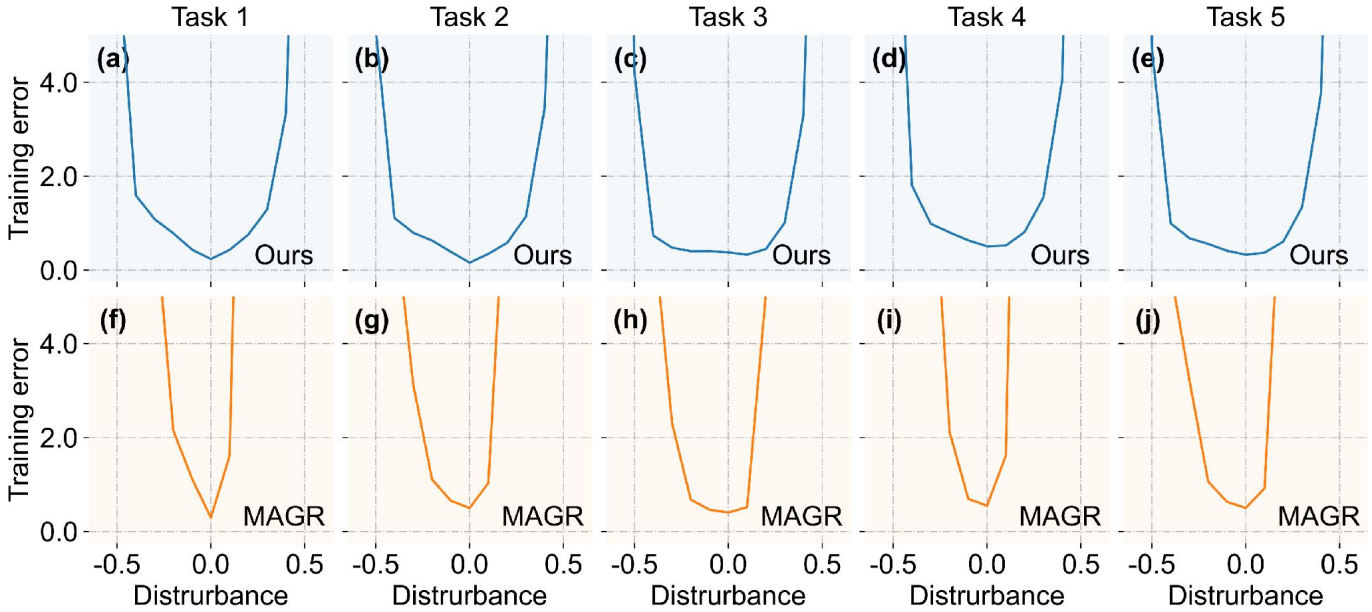
予測スコアと主観スコアの対応



横軸：人間の主観スコア、縦軸：予測スコア。1点が1動画
赤の破線：予測＝正解。オレンジ線：当てはめた回帰直線

ASALの回帰直線は、MAGRより理想線に近い

継続学習後のLoss Landscape



全5タスクの学習後、重みをランダムな方向にずらす
横軸：重みをずらす量。縦軸：各タスクの学習損失。10回の平均

考察

得られた結果

報告表の全体列では、ASALはJT・CLともに良好な結果

結果の解釈

Reparameterizationの効果は指標に依存する
Loss Landscapeは、重みを少し変えたときの損失の変化を測る

注意点

正式掲載版にも本文と表の不一致が残ることを確認済み
原因と、どちらが正しい実験値かは未確定

今後の展望

データセットの拡張

より多様で難しい360度動画を含むデータセットへ拡張する

動的なKeyframe選択とメモリ管理

コンテンツの変化に応じたKeyframe選択とメモリ管理を探究する

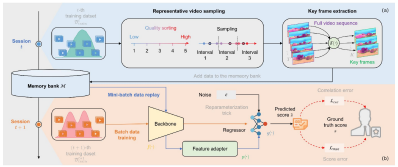
利用者からのリアルタイムなフィードバック

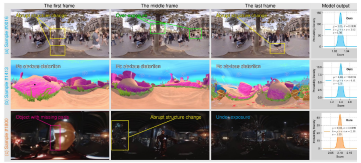
利用者の操作に基づくフィードバックを、モデルの継続的な改善に取り込む

リアルタイムなフィードバックは、今回のデータセット実験では実装していない

まとめ

360度動画の品質予測：スコア整合学習とAdaptive Memory Replay







対象

360度動画を見た人が感じる画質を予測
異なる種類の動画を順番に学習する

過去データの再利用

少数のフレーム画像とラベルを保存
Feature Adapterで全体の特徴を推定

評価の観点

相関と値のずれを分けて評価
順位が合うだけでは絶対値は合わない

実験から言えること

報告表では全体評価が良好
構成要素の効果は指標ごとに確認する

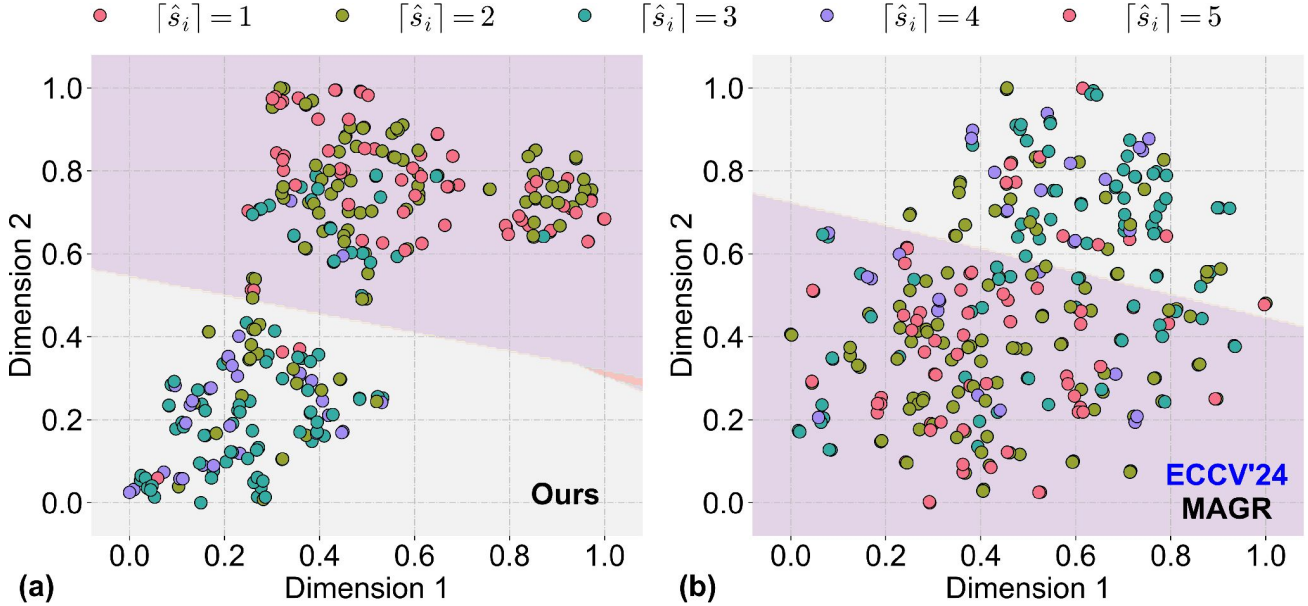
スコア予測の学習

スコア分布とReparameterization
Correlation LossとMSE Lossを併用

今後

多様なデータセットと動的なメモリ管理
利用者からのリアルタイムなフィードバックへの拡張

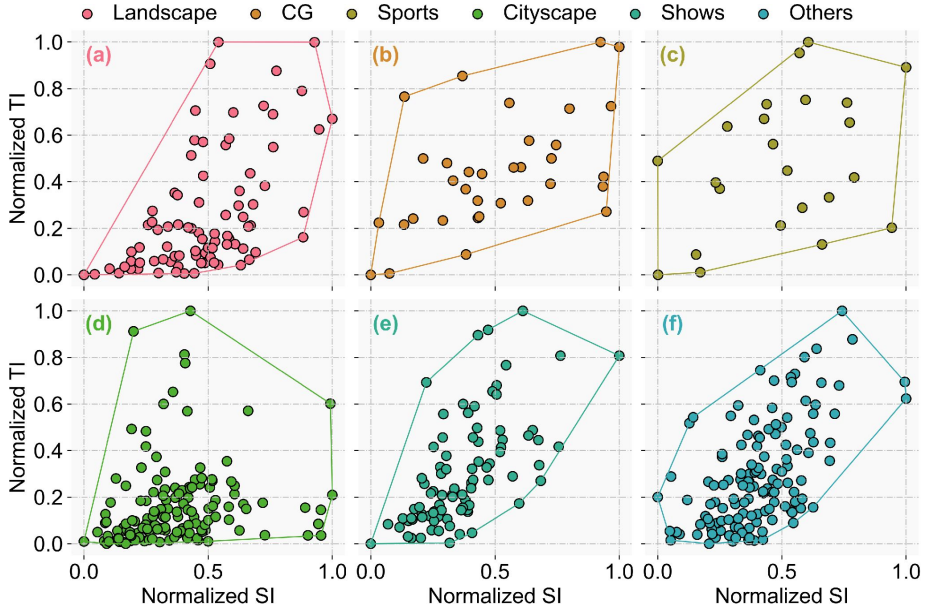
t-distributed Stochastic Neighbor Embedding (t-SNE)



特徴を2次元に配置。軸は品質スコアそのものではない
点の色は予測スコアの区分。背景領域の意味は未記載

著者はASALでスコアごとの分離が明瞭と説明する

Spatial Information (SI) / Temporal Information (TI)



SI：輪郭や細かい模様など、空間方向の情報
TI：隣接フレーム間の変化。物体やカメラの動きなど

品質の良さを直接表す指標ではなく、動画内容の多様性を示す

補足：PLCCとSRCCの式

PLCC：線形相関

$$\mathcal{L}_{\mathrm{cor}} = 1 - \mathrm{PLCC},\ \mathrm{PLCC} = \frac{\Sigma_i (s_i - \bar{s})(\hat{s}_i - \bar{\hat{s}})}{\sqrt{\Sigma_i (s_i - \bar{s})^2}\sqrt{\Sigma_i (\hat{s}_i - \bar{\hat{s}})^2}},$$

SRCC：順位相関

$$\mathrm{SRCC} = \frac{\Sigma_i \left(p_i - \bar{p}\right)\left(q_i - \bar{q}\right)}{\sqrt{\Sigma_i \left(p_i - \bar{p}\right)^2 \Sigma_i \left(q_i - \bar{q}\right)^2}},$$

SRCCは、スコアを順位へ置き換えたピアソン相関

補足：Reparameterizationの勾配

$$\frac{\partial \hat{s}}{\partial \mu} = 1, \qquad \frac{\partial \hat{s}}{\partial \sigma} = \epsilon$$

乱数εを一度引いて固定すると、μとσに対して微分できる

任意の全ての乱数で誤差を0にすることを要求していない

MSEだけなら、分散を縮める方向の圧力がある

$$\mathbb{E}_{\epsilon}\left[(s - \hat{s})^2\right] = (s - \mu)^2 + \sigma^2$$

確率化だけで平滑化や汎化の改善が保証されるわけではない

補足：Feature Regularization

段階	得られるもの
全フレームをfで処理	元の動画特徴 h：T×D
φで一部を選択	Keyframeに対応する特徴：K×D
pで全体を推定	再構成特徴 ĥ：T×D
元と再構成を比較	Lreg。pと、固定しなければfを更新

$$\mathcal{L}_{\text{reg}} = \sum_i \|\mathbf{h}_i^t - \hat{\mathbf{h}}_i^t\|_2, \qquad \hat{\mathbf{h}}_i^t = p(\phi(\mathbf{h}_i^t))$$

現在の動画には全フレームがあるため、再構成の比較対象を作れる

補足：二つのサンプリング

対象	何をそろえるか	目的
タスク間の学習動画	カテゴリごとの学習本数	データ量の偏りを抑える
メモリ内の代表動画	品質順の選択間隔	スコアの範囲を代表する

品質ごとの等本数化と、カテゴリごとの等本数化は異なる

補足：Keyframe選択の定式化

$$\tilde{\boldsymbol{x}}_k = \arg\max_{\boldsymbol{x}_i} \ \mathcal{S}(\mathbf{x}_i), \quad \text{for } k = 1, 2, \ldots, K,$$

$$\min \sum_{i \neq j} \mathrm{Sim}(\tilde{\boldsymbol{x}}_i, \tilde{\boldsymbol{x}}_j),$$

S：動画品質に関するフレームの重要度を表す関数

Sim：選択フレームどうしの類似度

Residual Network (ResNet)は特徴を得る手段。Sの具体式は未記載

フレームの重要度と多様性を同時に扱う選択手順は、本文だけでは確定しない

補足：論文と公開実装の区別

箇所	論文の記述	公開実装
Keyframe	重要度と類似度の目的	ResNet特徴のKMeans代表
Lreg	二乗なしL2ノルム	F.mse_loss
Lreg用の特徴選択	φによる選択	フレームのランダムな部分集合
学習更新	複合目的を提示	現在データ更新の後、別にReplay更新

手法の説明は論文、実装の説明はコードと出典を分ける

補足：比較手法の正式名称

略称	正式名称・説明
EWC	Elastic Weight Consolidation
LwF	Learning without Forgetting
MER	Meta-Experience Replay
TOPIC	TOpology-Preserving knowledge InCrementer
NC-FSCIL	Neural Collapse inspired framework for Few-Shot Class-Incremental Learning
SLCA	Slow Learner with Classifier Alignment

比較表の手法名は、元の論文の表記を使う

補足：全条件のSRCC

手法	7A	7B	7A&B	15A	15B	15A&B	全体
JT	0.7747	0.8213	0.7572	0.8730	0.9102	0.8343	0.7932
Seq FT	0.4400	0.3930	0.4211	0.5233	0.4472	0.4808	0.4567
SI	0.5513	0.6928	0.6342	0.6862	0.6114	0.6053	0.6227
EWC	0.2038	0.5030	0.3538	0.5600	0.3160	0.4362	0.4126
LwF	0.4719	0.6051	0.5393	0.6085	0.4748	0.5373	0.5495
MER	0.5029	0.4961	0.4962	0.5133	0.5582	0.5223	0.5190
DER++	0.4773	0.5698	0.5309	0.7095	0.5415	0.6155	0.5825
TOPIC	0.4315	0.5760	0.4897	0.6266	0.4862	0.5283	0.5148
NC-FSCIL	0.2227	0.2632	0.2609	0.4434	0.2704	0.3844	0.3357
SLCA	0.3983	0.3318	0.3665	0.4534	0.2111	0.2951	0.3290
MAGR	0.4865	0.6036	0.5386	0.6179	0.3711	0.4852	0.5089
ASAL	0.6371	0.7280	0.6936	0.7335	0.7235	0.7149	0.7148

JT行は共同学習、他の行は継続学習の集約指標

補足：全条件のRL2E

手法	7A	7B	7A&B	15A	15B	15A&B	全体
JT	0.0273	0.0289	0.0222	0.0358	0.0166	0.0194	0.0193
Seq FT	0.1152	0.1247	0.0907	0.1028	0.0712	0.0717	0.0712
SI	0.0516	0.0473	0.0370	0.0416	0.0444	0.0362	0.0328
EWC	0.1175	0.0634	0.0654	0.0400	0.0834	0.0534	0.0523
LwF	0.0625	0.0544	0.0435	0.0400	0.0506	0.0384	0.0364
MER	0.0655	0.0646	0.0488	0.0483	0.0545	0.0433	0.0409
DER++	0.0652	0.0586	0.0462	0.0323	0.0512	0.0357	0.0359
TOPIC	0.0593	0.0674	0.0480	0.0573	0.0401	0.0401	0.0389
NC-FSCIL	0.0735	0.0811	0.0585	0.0539	0.0573	0.0467	0.0462
SLCA	0.0926	0.0765	0.0628	0.0402	0.0896	0.0563	0.0530
MAGR	0.0707	0.0527	0.0455	0.0371	0.0624	0.0427	0.0394
ASAL	0.0517	0.0367	0.0325	0.0308	0.0353	0.0279	0.0267

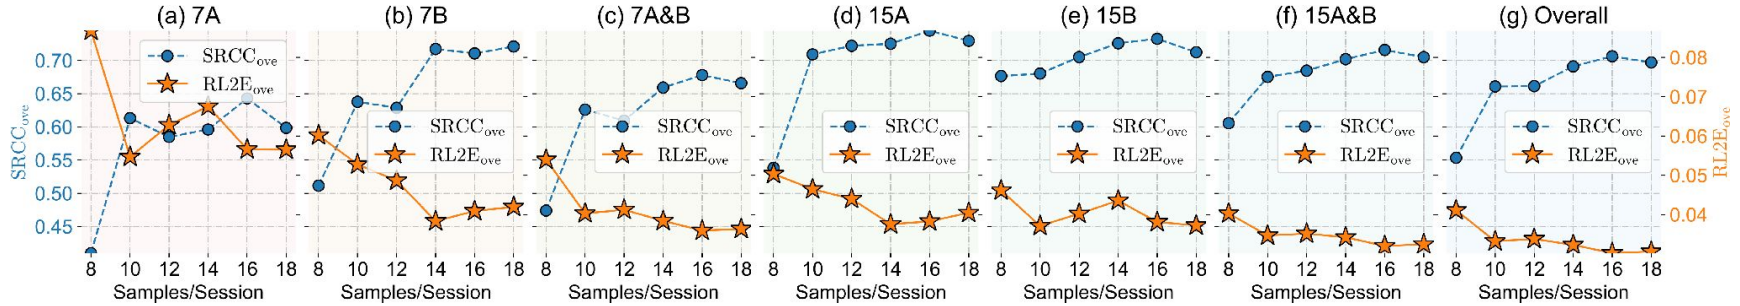
JT行は共同学習、他の行は継続学習の集約指標

補足：原論文内の不一致

箇所	本文	表・図
ASALのJT全体	SRCC 0.7978 / RL2E 0.0210	表：0.7932 / 0.0193
Reparameterization除去	RL2Eが0.0210→0.0181に増加	数値は減少。表は0.0193→0.0181
CLの次点	MAGR 0.5089を挙げる	表3：SIは0.6227
動画条件	7A / 7B / 14A / 14B	表：15A / 15Bを使用
図9の回帰式	切片0.48	図：切片0.45、凡例は軸と不整合

正式掲載版でも、本文と表の不一致が残っている

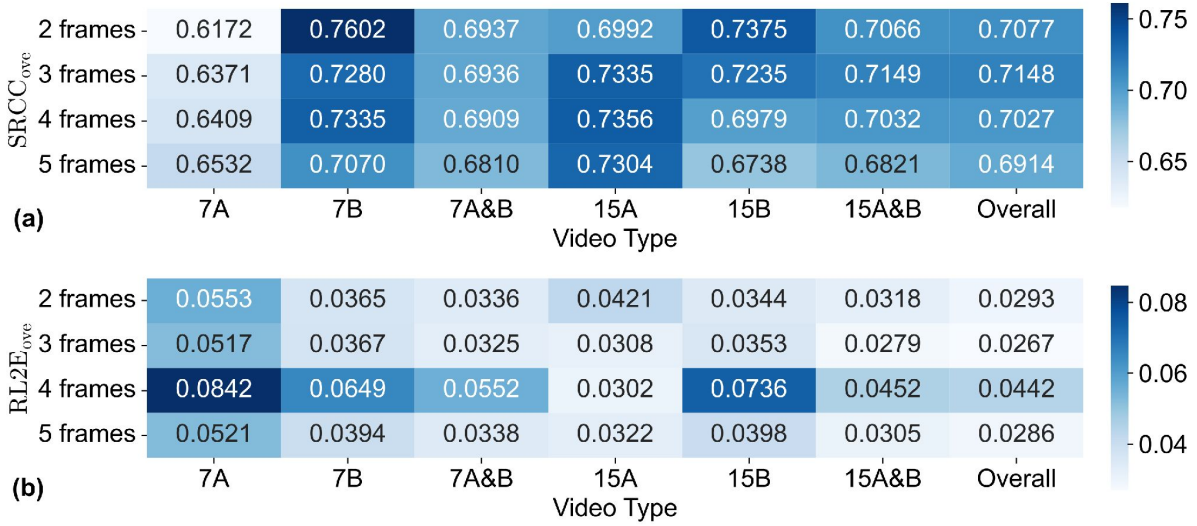
代表サンプル数の影響



各セッションの保存サンプル数を8〜18で比較
本文は16程度のバランスを挙げる。図の各条件も確認する

このデータ・設定での感度分析として読む

Keyframe数の影響



保存するKeyframeを2〜5枚で比較
全体列では3枚が相関・誤差ともに最良

3枚でSRCCove＝0.7148、RL2Eove＝0.0267

補足：参考文献と確認範囲

対象論文	Zhou et al. Adaptive Score Alignment Learning… IEEE TVCG 31(5), 2880–2890, 2025 DOI: 10.1109/TVCG.2025.3549179
品質ラベル・視聴条件	Wen et al. Perceptual Quality Assessment of Virtual Reality Videos in the Wild. TCSVT 34(9), 8368–8381, 2024 arXiv:2206.08751v3
関連手法	Zhou et al. MAGR. ECCV 2024 Tang et al. Deep Unsupervised Key Frame Extraction… ACM TOMM 19(3), 2023
公式コード	github.com/ZhouKanglei/ASAL_CVQA 論文と公開実装の相違は補足の比較表を参照