Lovanshi, Mayank, and Vivek Tiwari.

"Human skeleton pose and spatio-temporal feature-based activity recognition using ST-GCN."

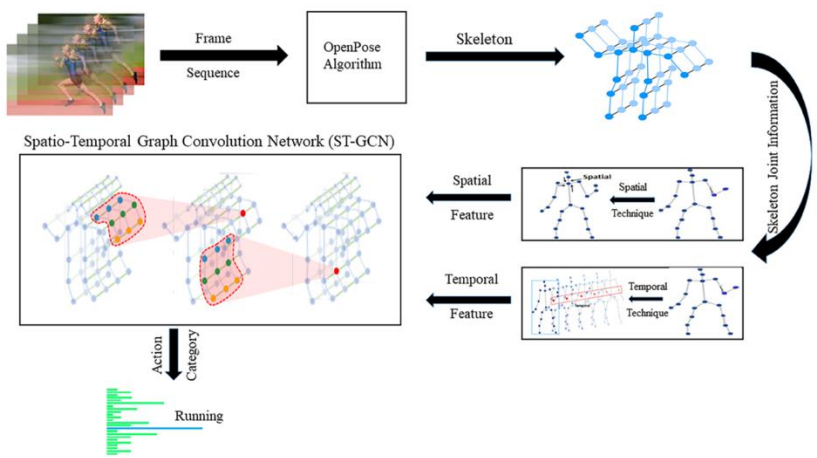
Multimedia Tools and Applications 83.5 (2024): 12705-12730.

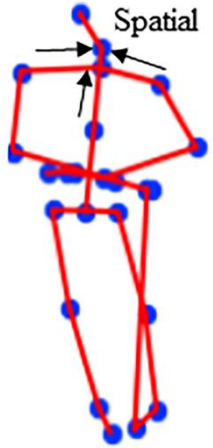
2026/11/11

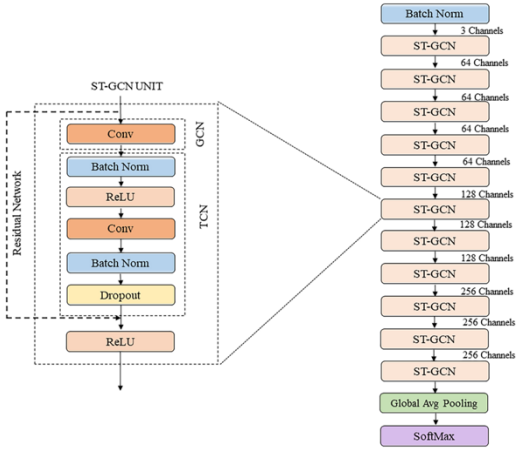
神戸大学

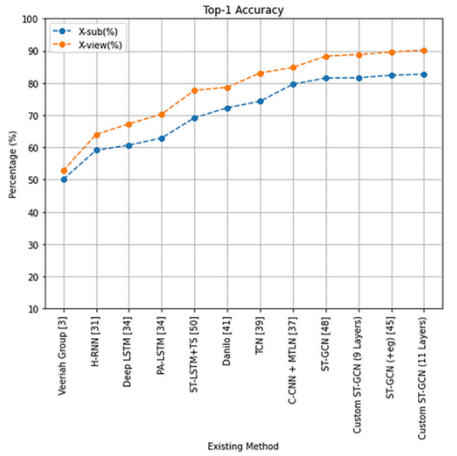
松﨑 吏矩

要点









どんなもの？

骨格座標の時空間特徴と
改良型11層Custom ST-GCNによる人間行動認識手法を提案

どうやって有効だと検証した？

NTU-RGB-D・Kinetics・Florence 3Dの3種データセットで
Top-1精度 +0.7% / +1.25% / +1.92% の向上を実証

先行研究と比べてどこがすごい？

3大ベンチマークでSOTA精度を更新、推論0.0213秒に短縮

議論はある？

- **短時間の局所特徴中心**で長期的な時間依存性の捕捉に制約
- **複数人環境**での骨格追跡や**ハイパーパラメータ感度**が課題

技術や手法のキモはどこ？

- ガウシアンフィルタ平滑化と距離・極値差分による時空間特徴抽出
- ユニット内の**2層GCN**化および**グラフ注意機構**(GAM)・Causal TCN

次に読むべき論文は？

Spatial Temporal Graph Convolutional Networks for
Skeleton-Based Action Recognition (Yan et al., AAAI 2018)

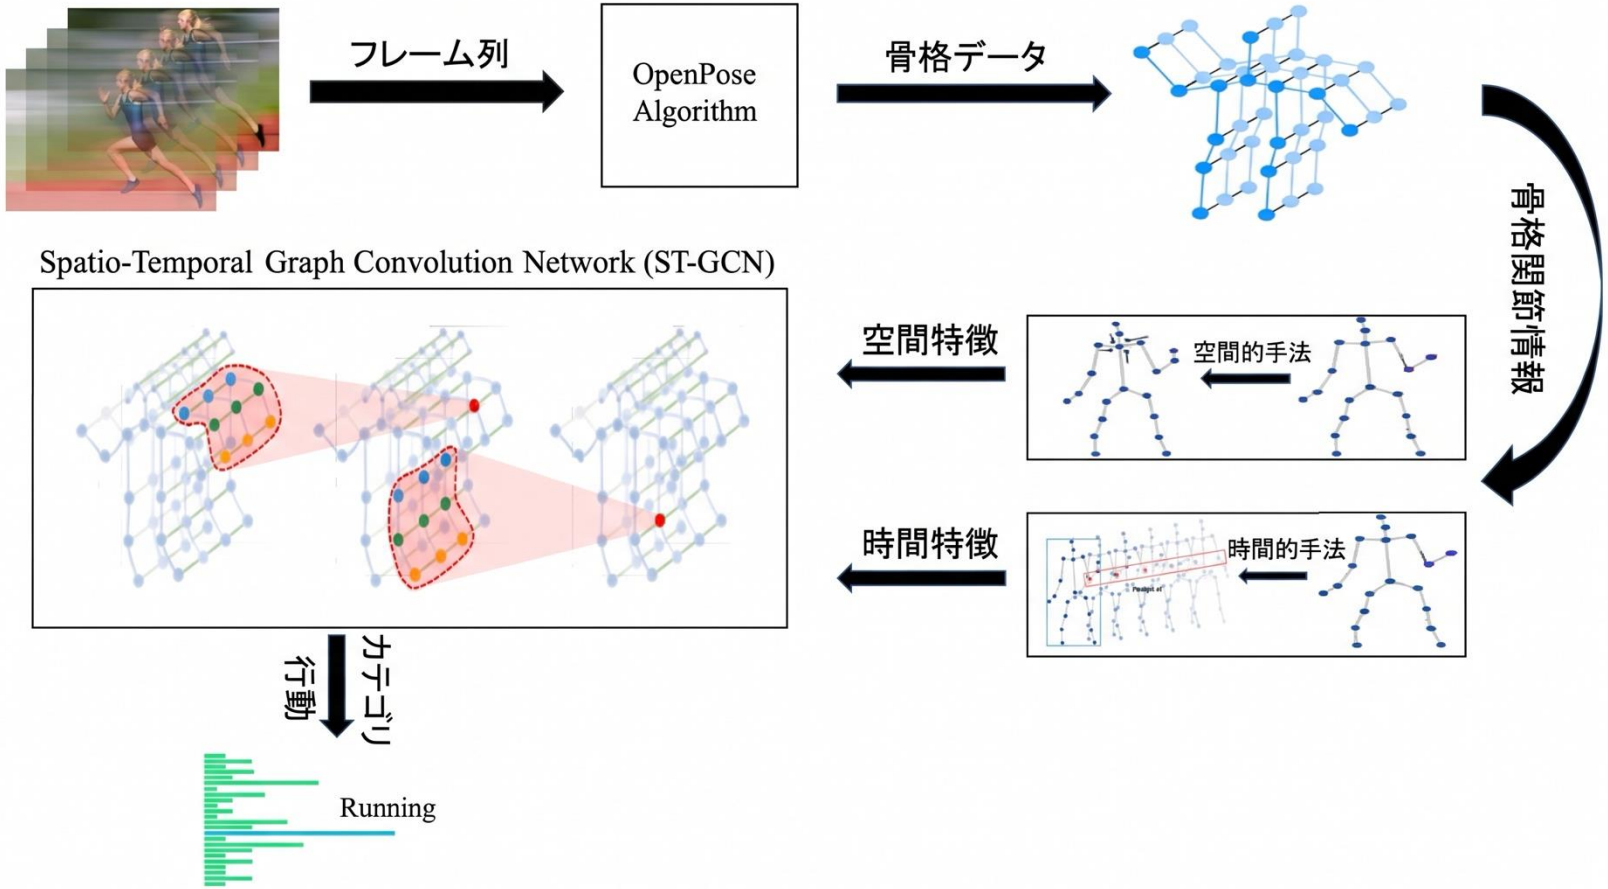
先行研究・研究背景

- **人間行動認識**
  - **医療(パーキンソン病監視・転倒検知) ・監視・スマートホーム**等で需要が拡大
  - 照明・背景変化や遮蔽に弱いRGB画像に対し、視点・体型に不変な**3D骨格データ**が優位
- **課題**
  - 骨格抽出時に混入する**座標ノイズの平滑化処理**が不十分
  - 非隣接間接を含む**空間的な連結関係と時間的な運動変化の同時モデリング**が困難
  - 既存研究は単一データセットでの検証に偏り、**複数ベンチマークでの汎用性評価が不足**

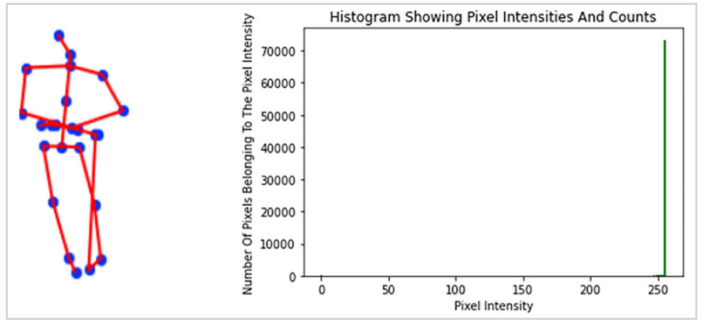
➡ **ガウシアン平滑化＋時空間特徴抽出**と
Custom ST-GCNで高精度・高速に行動認識

提案手法：Custum ST-GCN

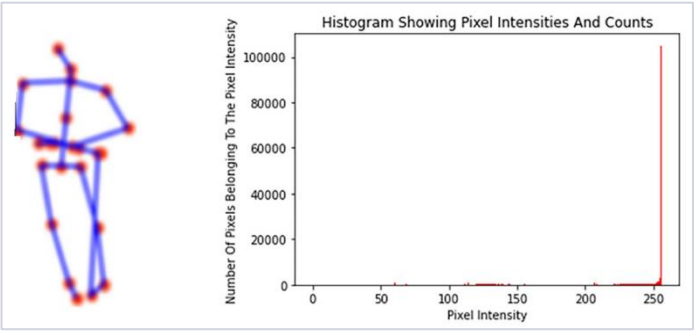
- 全体フロー



- ガウシアン平滑化



処理前：7.2万px

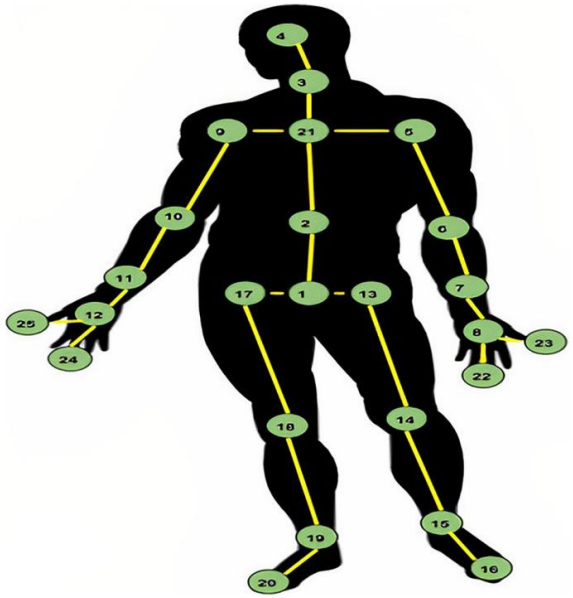


処理後：11万px

提案手法：時間・空間特徴の抽出プロセス

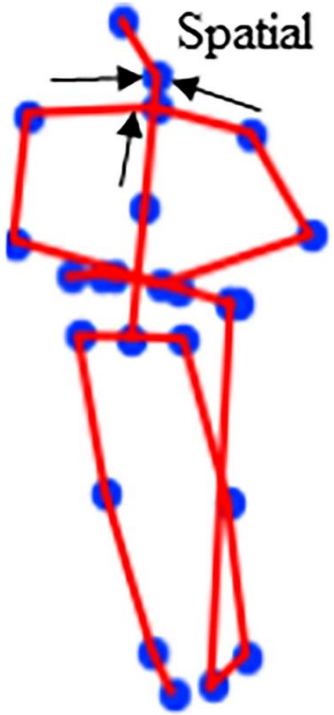
①3Dガウシアンフィルタによる骨格データの平滑化

$$G_\sigma = \frac{1}{2\pi\sigma^2} e^{-\frac{(x^2+y^2+z^2)}{2\sigma^2}}$$

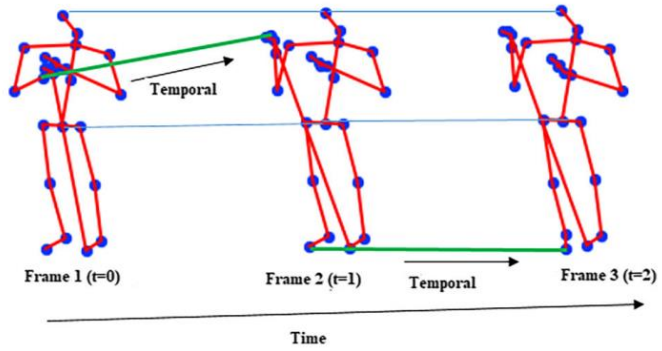


3次元座標 (x, y, z) のノイズを除去し、後段の距離・変位計算を安定化

②空間特徴チャネル f_s (2×N²)
全関節ペア間の
ユークリッド距離行列Edistanceと
コサイン距離行列Cdistanceを結合
f_s = Concat(Edistance, Cdistance)

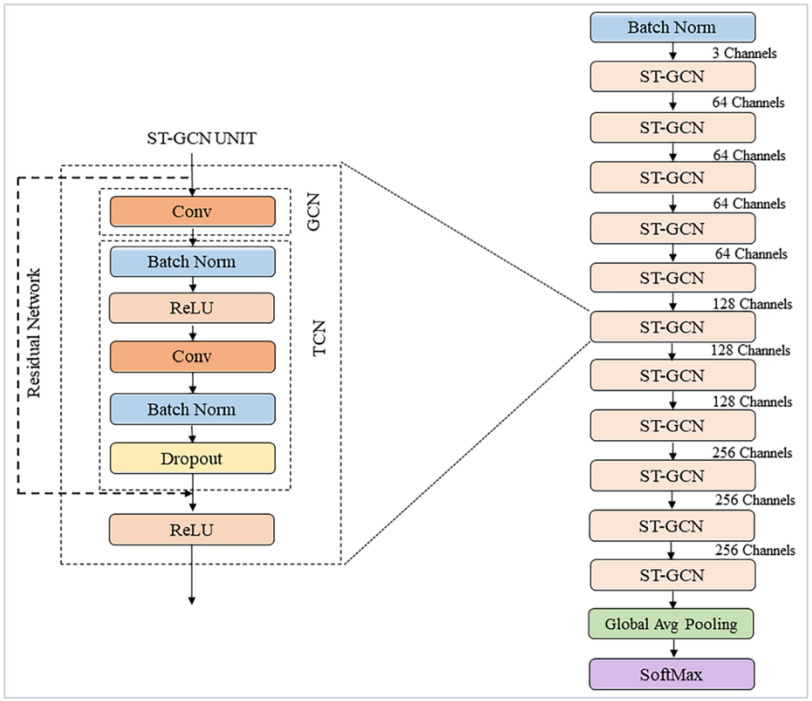


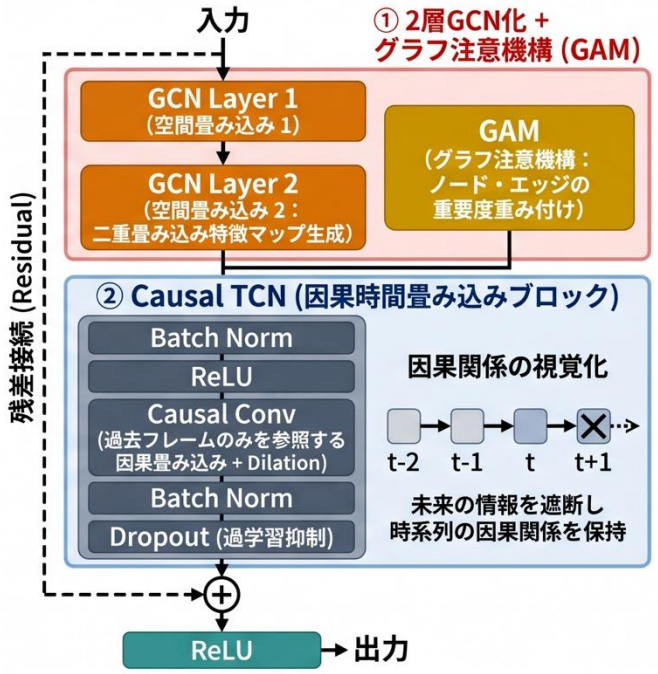
③時間特徴チャネル f_t (2×N)
全フレーム中の各関節座標の最大値・最小値との平均差分 J_i,max, J_i,min を算出
f_t = (J_1,min… J_N,min, J_1,max… J_N,max)



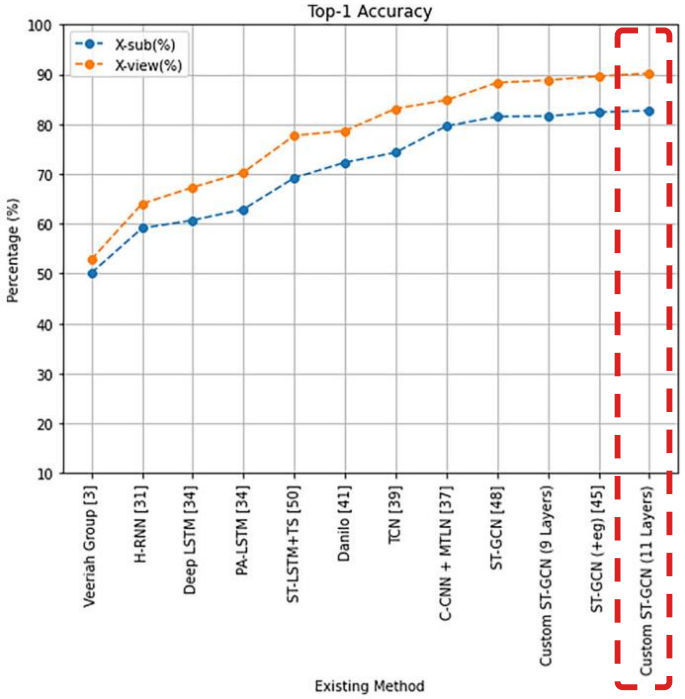
提案手法：アーキテクチャ

- **2層GCN＋Causal TCN＋Graph Attention (GAM) を備えた11層ネットワーク**
  - 11層のST-GCNユニット構成：
    入力3ch(3D座標) → 64ch(×4層) → 128ch(×4層) → 256ch(×3層) → Global Avg Pooling → SoftMax
  - ユニット内の2層GCN化：従来の単一GCNを2層のGCNに拡張し、二重畳み込み特徴マップをTCNへ伝達
  - Causal TCNとGAMの結合：過去の時系列のみを参照する因果畳み込み(BN→ReLU→Conv→BN→Dropout) とグラフ注意機構 (GAM) を統合

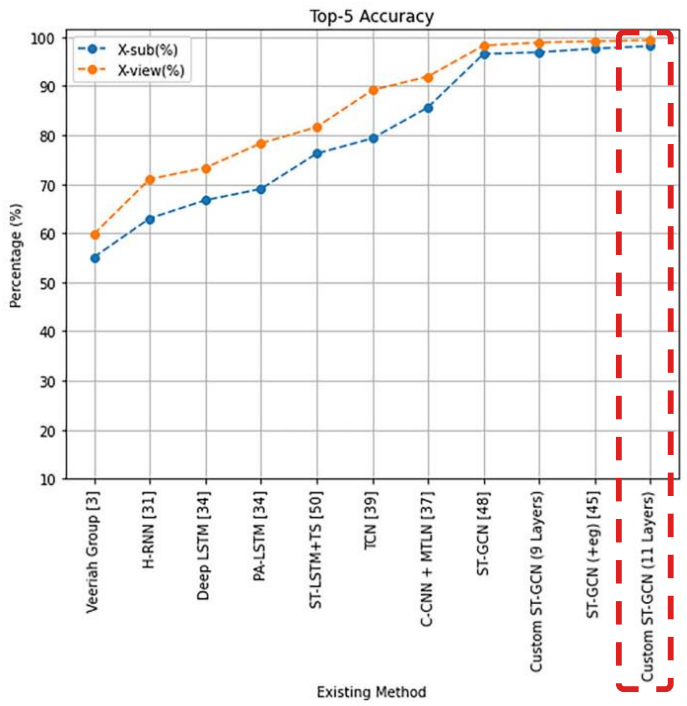




実験結果：定量比較



NTU-RGB-D Top-1精度比較



NTU-RGB-D Top-5精度比較

Table 3 Performance comparison with Top-1 & Top-5 accuracy on Kinetics skeleton

Existing methods	Top 1	Top 5
Feature Enc. ([12])	14.90%	25.80%
Deep LSTM ([28])	16.40%	35.30%
Temporal Conv. ([17])	20.30%	40.00%
ST-GCN ([51])	30.70%	52.80%
Custom ST-GCN (9 Layer)	31.60%	54.1%
ST-GCN (+eg) ([47])	31.90%	54.1%
Custom ST-GCN (11 Layer)	**32.30%**	**54.50%**

Table 4 Performance comparison with accuracy on Florence 3D

Existing methods	Accuracy
Multi-part Bag-of-Poses ([26])	82.00%
Riemannian Manifold ([8])	87.04%
Lie Group ([34])	90.88%
Graph-Based ([22])	91.63%
MIMTL ([50])	95.29%
P-LSTM ([28])	95.35%
ST-GCN([51])	96.25%
Custom ST-GCN (9 Layer)	97.60%
Custom ST-GCN (11 Layer)	**98.10%**

- **NTU-RGB-Dで最高精度を達成**
  X-Sub：**Top-1 82.7% / Top-5 98.1%**
  X-View：**Top-1 90.2% / Top-5 99.3%**
  （既存SOTA比 Top-1 +0.7%, Top-5 +0.5%）
- **Kinetics-SkeletonでもSOTA凌駕**
  Custom ST-GCN (11層) が
  Top-1 32.30% / Top-5 54.50% を記録
  （従来ST-GCN比 +1.6%, SOTA比 +1.25%）
- **Florence 3Dで 98.10% の高精度**
  従来ST-GCN (96.25%) から **+1.92%向上**

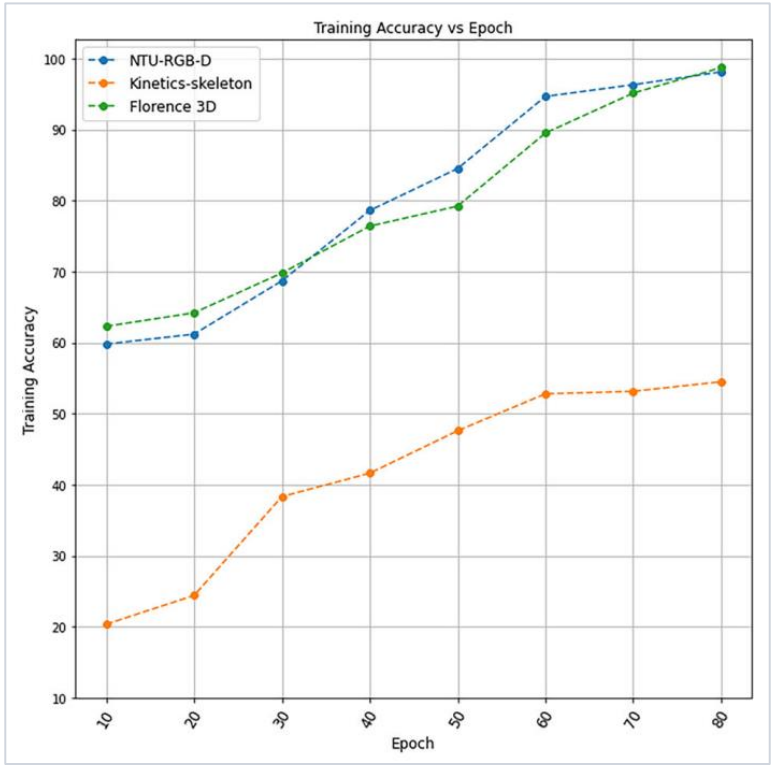
実験結果：データセット横断評価と学習収束性

3種の検証データセット仕様(Table 2)

Table 2 Dataset description of skeleton dataset

SN.	Parameter	NTU-RGB-D	Kinectics-400	Florence- 3d
1	# of clips	56880	306245	21864
2	Size of dataset	5.8 GB	42.2 GB	2.1 GB
3	# of Activity/ classes	60	400	215
4	# of joints	25	20	15
5	# of body information	10	-	10

エポック数に対する学習精度の推移（Fig. 11）



Custom ST-GCN (11層) 総合性能比較(Table 5)

Table 5 Custom ST-GCN (11-Layer) model performance with datasets

Parameter		Top 1	Top 5	Mean Loss
NTU-RGB-D	X-view	90.20%	99.3%	0.33
	X-Sub	82.70%	98.10%	0.61
Kinetics Skeleton		32.30%	54.50%	3.01
Florence 3D		98.10%	98.70%	0.087

関節数(15～25)・クラス数(60～400)・撮影環境の異なる3データセット全てで高い汎化性能を実証

- 単一データセット評価が主流だった先行研究に対し、本研究は3大ベンチマーク横断で一貫した優位性を確認

実験結果：計算効率と今後の展望

Table 6 Complexity comparison with GFLOPS & Inference Time of ST-GCN vs Custom ST-GCN

Existing method	GFLOPS	Inference Time(s)
ST-GCN ([51])	13.72	0.0251
Custom ST-GCN (11-Layer)	**17.5**	**0.0213**



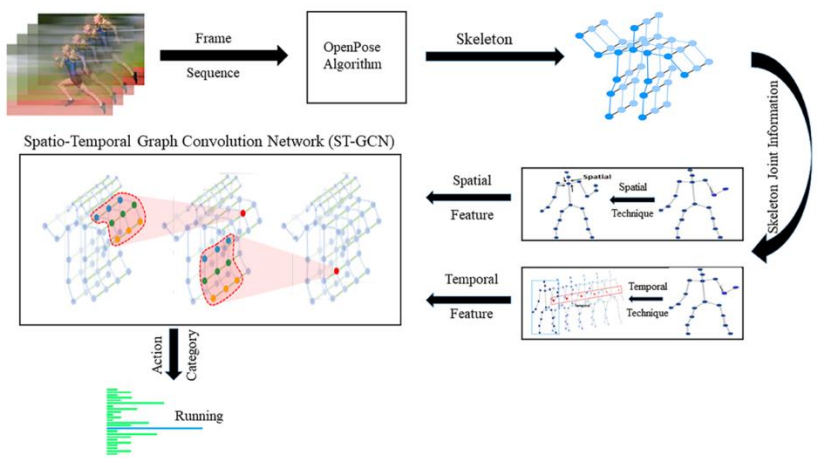
計算量と推論速度

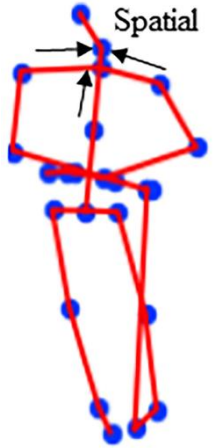
- GFLOPS：**17.5 GFLOPS**
  (従来ST-GCN: 13.72)
- 推論時間：**0.0213秒**
  従来(0.0251秒)より**約15%高速化**

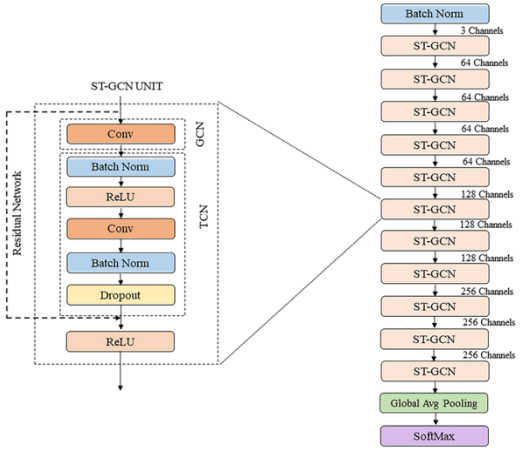
限界と今後の課題

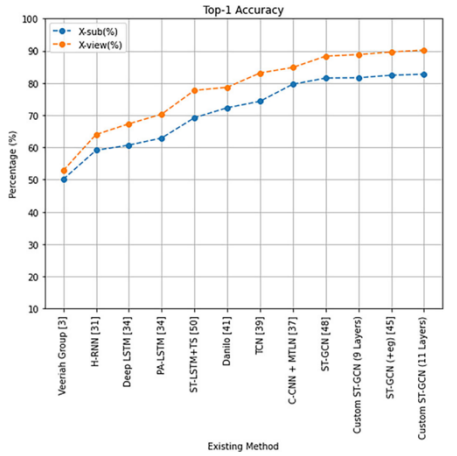
- 限界
  - 短時間の局所特徴中心で**長期時間依存性**の捕捉に限界
  - ハイパーパラメータ感度が高い
- 今後の課題
  - **複数人骨格の同時追跡**
  - 文脈(物体・場所)統合へ拡張
  - 医療への応用(パーキンソン病診断など)

要点









どんなもの？

骨格座標の時空間特徴と
改良型11層Custom ST-GCNによる人間行動認識手法を提案

どうやって有効だと検証した？

NTU-RGB-D・Kinetics・Florence 3Dの3種データセットで
Top-1精度 +0.7% / +1.25% / +1.92% の向上を実証

先行研究と比べてどこがすごい？

3大ベンチマークでSOTA精度を更新、推論0.0213秒に短縮

議論はある？

- **短時間の局所特徴中心**で長期的な時間依存性の捕捉に制約
- **複数人環境**での骨格追跡や**ハイパーパラメータ感度**が課題

技術や手法のキモはどこ？

- ガウシアンフィルタ平滑化と距離・極値差分による時空間特徴抽出
- ユニット内の**2層GCN**化および**グラフ注意機構**(GAM)・Causal TCN

次に読むべき論文は？

Spatial Temporal Graph Convolutional Networks for
Skeleton-Based Action Recognition (Yan et al., AAAI 2018)