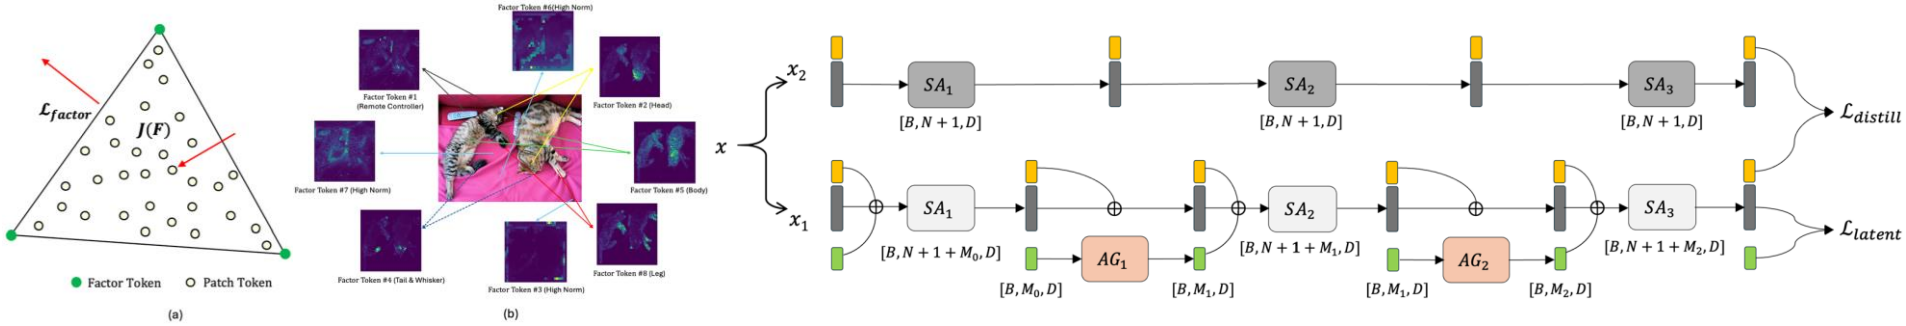
# The Extra Tokens Matter: Disentangled Representation Learning with Vision Transformers

Maofeng Tang, Hairong Qi, ICML, 2026






## どんなもの？

**教師なしで画像を意味的なパーツ単位へと直交分解**する表現学習フレームワーク**XTRA**を提案

## 先行研究と比べてどこがすごい？

**従来手法よりも高い因子分離スコアを示しつつ**
**下流タスク精度やロバスト性も大幅に向上**

## 技術や手法のキモはどこ？

1. **幾何学的な線形混合モデル**
2. **Hard Assignmentを伴う多段階集約機構**

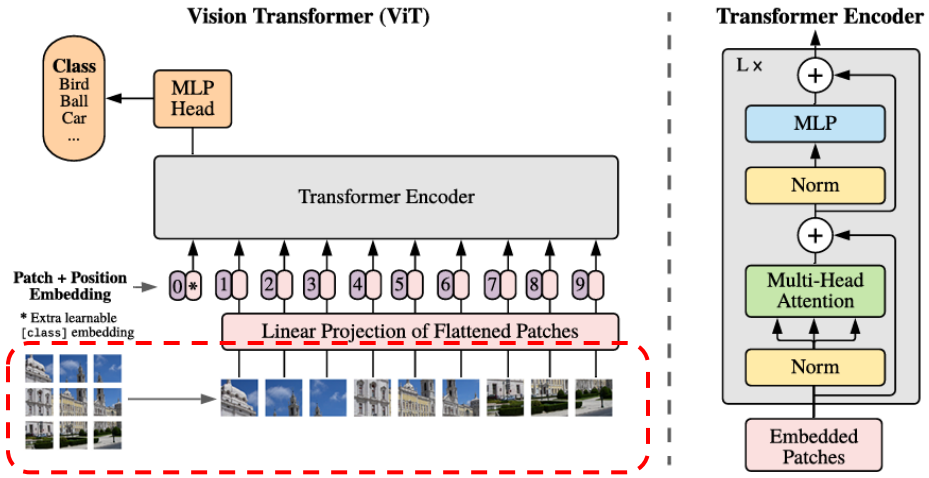
## どうやって有効だと検証した？

ImageNet-1Kでの因子分解指標や
PartImageNetでのパーツ分割精度を通じて
**明確な分解能力を立証**

## 議論はある？

- クラス内分散が低い剛体オブジェクトでの分離性能低下
- 因子の自動テキストラベル付け・生成モデルへの展開が未達成

# Vision Transformer




**Vision Transformerのモデル概観**

(Dosovitskiy et al., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", ICLR 2021, Fig. 1.)

## ・メカニズム

1. **パッチ分割**
   - 画像を固定サイズ(e.g. 16×16)のパッチへ分割しトークン化
2. **Self-Attention(自己注意機構)**
   - パッチトークン間の大域的な相互作用を計算し、画像内の空間的・意味的な位置関係を把握
3. **[CLS]トークン**
   - 最終的に画像全体の「大域的表現」を集約

➡ **画像タスクに対して高い精度**

# 背景・先行研究

- **従来のVision Transformer**
  - **Implicit & Entangled(暗黙的・もつれ)**
    - **大域的特徴抽出に優れている**
    - ピクセル単位でのみ反応
    - **パーツの境界が不明瞭**
    - **課題：背景やテクスチャへの過依存**

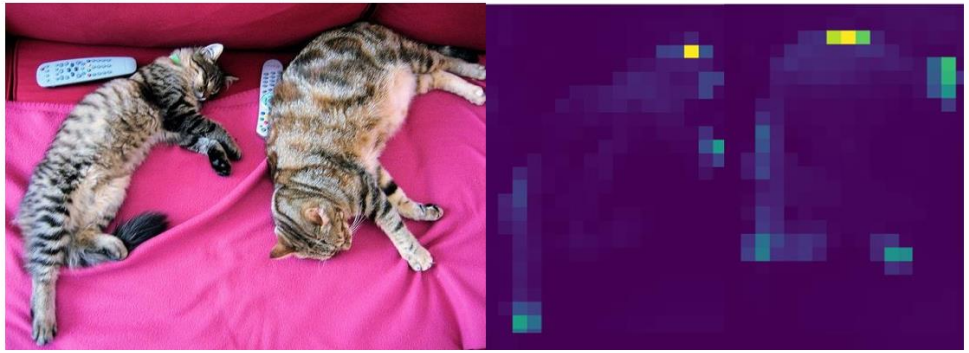


Figure.1a Vision transformer — global object representation

- **提案手法 XTRA**
  - **Explicit & Disentangled(明示的・分離)**
    - **教師なしで「頭」「足」「体」といった意味的まとまりで分離**
    - **ゼロショットでのパーツ認識や解釈性・ロバスト性の向上**

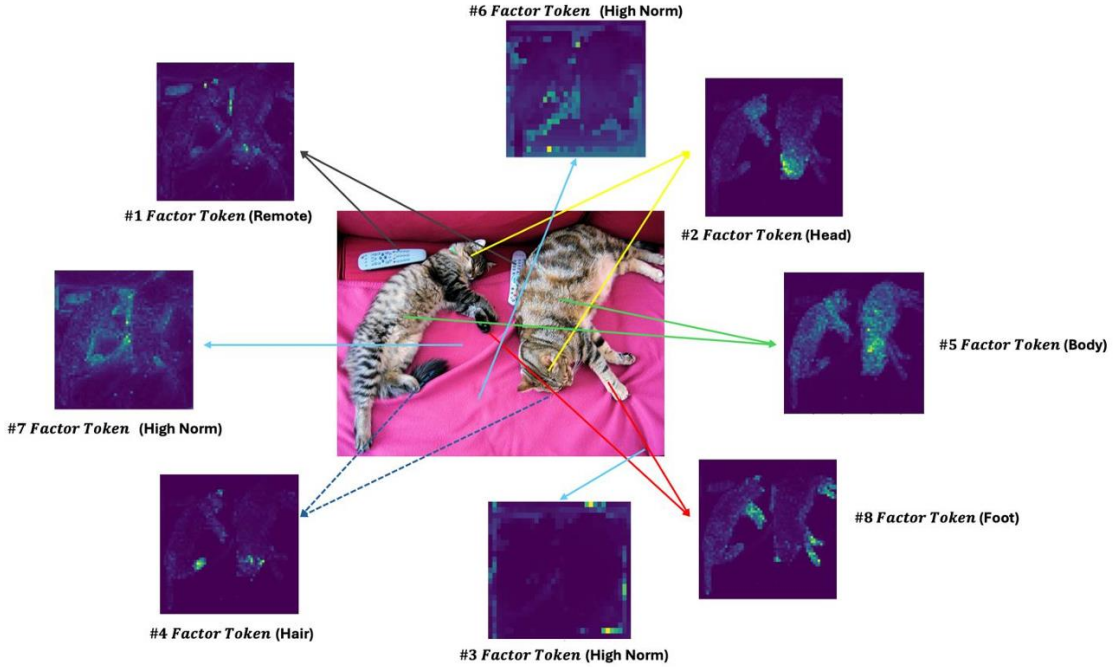



Figure.1b XTRA — explicit semantic parts

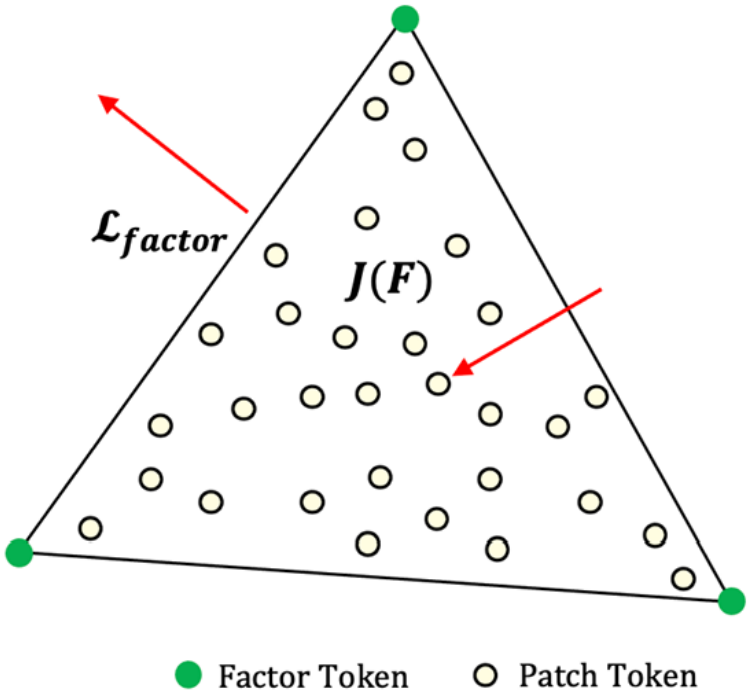
# 提案手法：XTRA (eXtra Token-based RepresentAtion learning)

- **潜在空間における線形混合モデル**（Linear Mixing Model）

  - **仮説：パッチトークンは意味的要因の凸結合として表される**

$$p_i = F \cdot w_i + \varepsilon_i$$

  - $p_i$：パッチトークン(観測データ)
  - $F$：Factor Tokenセット
  - $w_i$：混合比率(重み)
  - $\varepsilon_i$ ：ノイズ



# 提案手法：MVC（Minimum Volume Constraint）

- **最小体積制約(MVC)によるFactor Tokenの特定**
  - 潜在損失

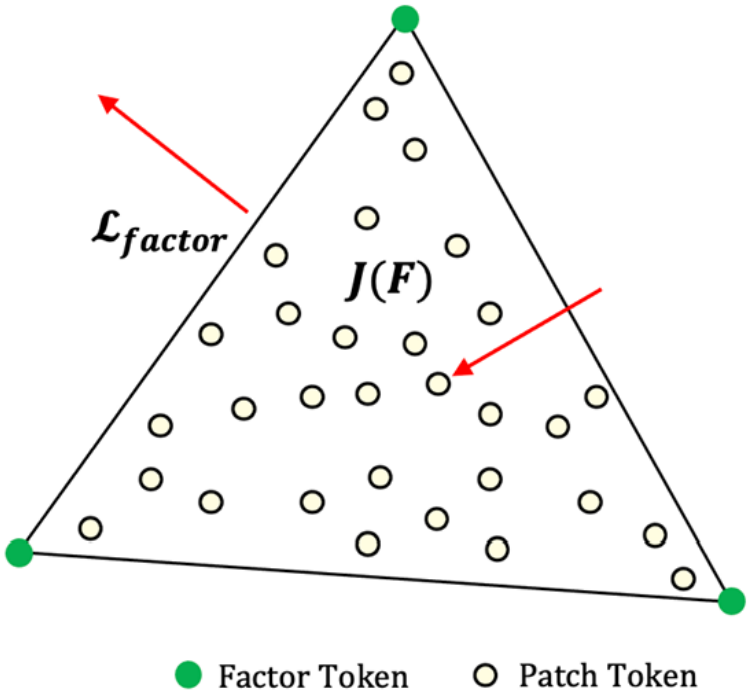
$$L_{latent} = \lambda_{latent} L_{factor} + \lambda_{volume} J(F)$$

1. $L_{factor}$：**再構成損失**
   - **外向きの引力**：全パッチを包み込む制約

$$L_{factor} = \frac{1}{2} log(\sum_{i=1}^{N} ||p_i - Fw_i||^2)$$

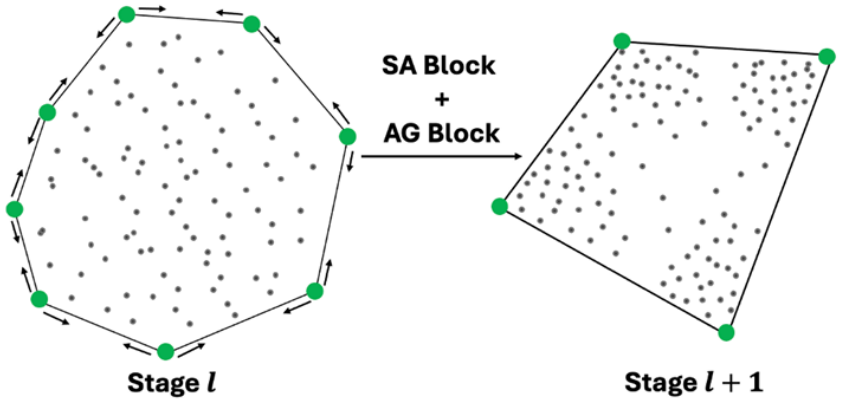
2. $J(F)$：**MVC**
   - **内向きの圧力**：凸包の体積を最小化する制約(直交化)

$$J(F) = ||F^T F - I||_F^2$$



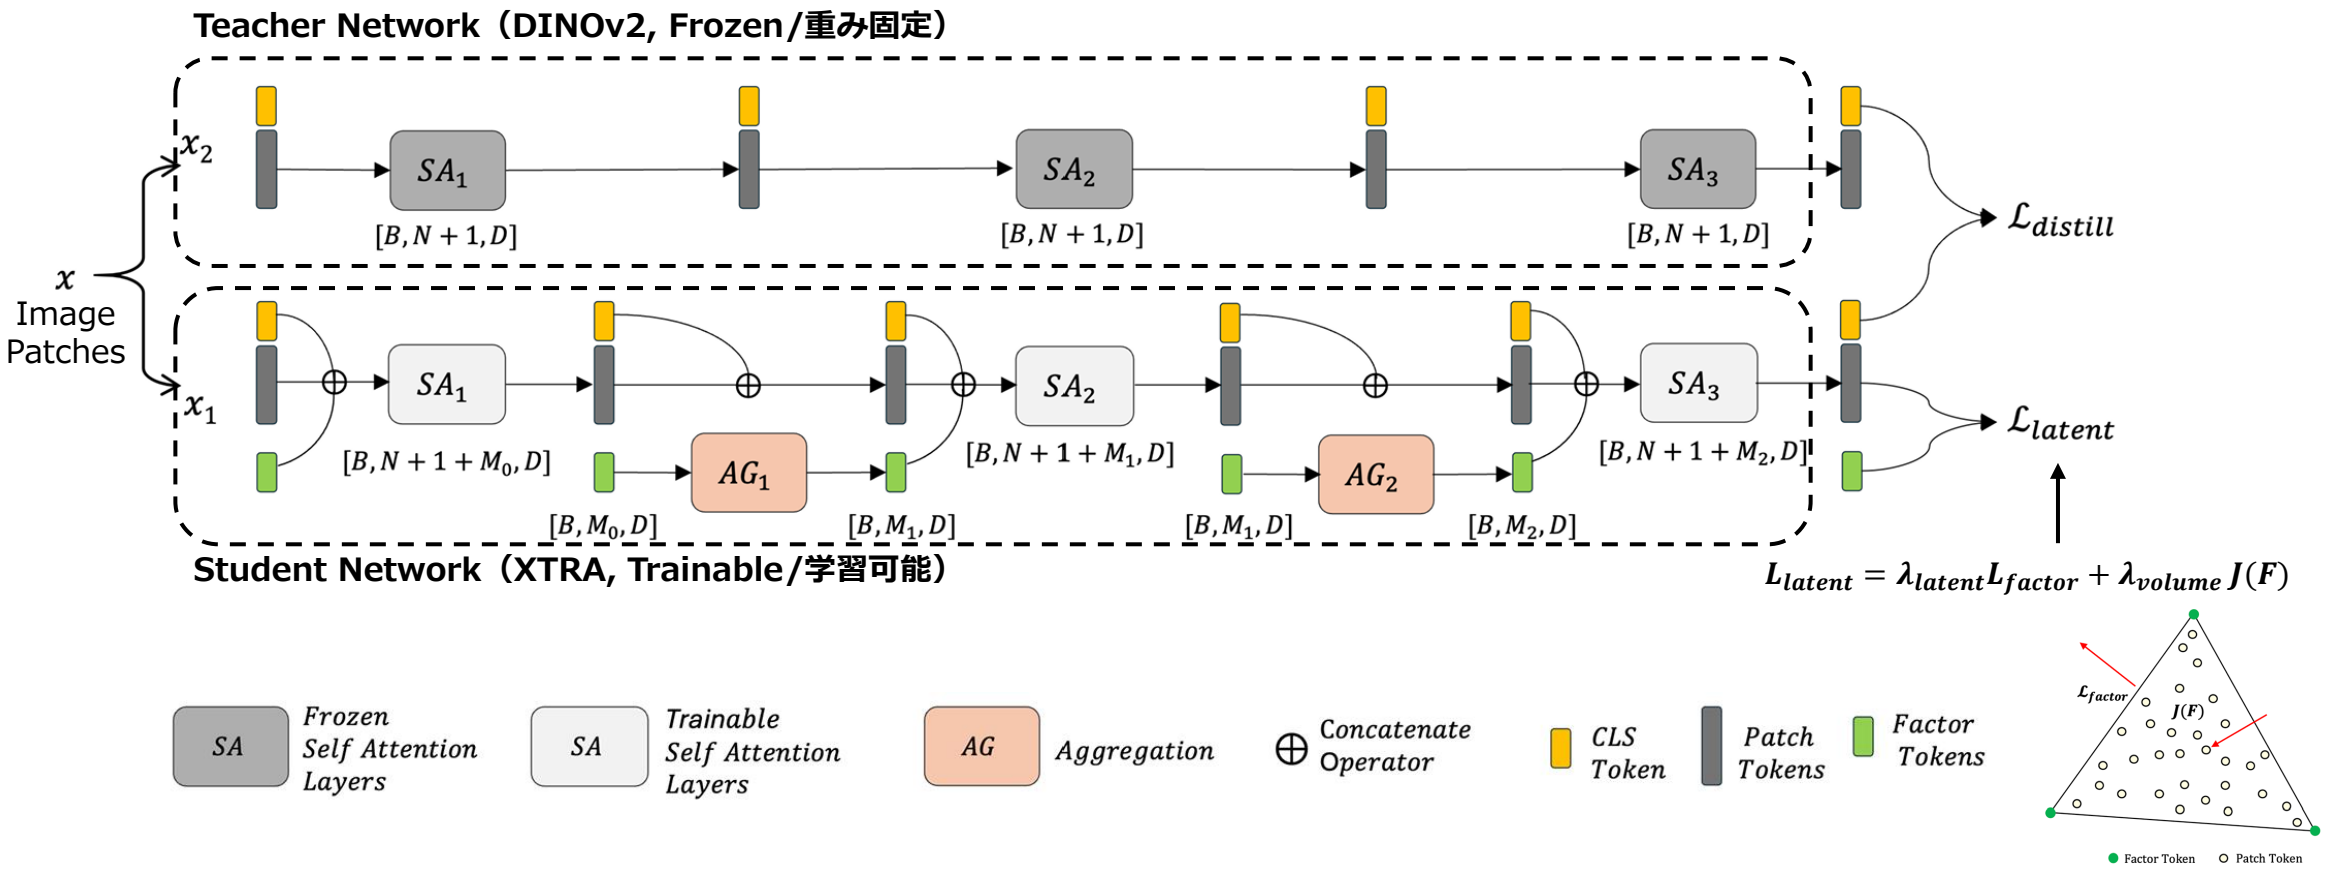
# 提案手法：Multi-Stage Aggregation Block

- **Factor Tokenの集約メカニズム**
  - **課題**
    - 層を深くしていくとFactor Token同士が似通ってしまう（**Over-smoothing**）
  - **手法**
    1. **Aggregation Block（集約ブロック）**
       - 層が深くなるにつれて類似するFactor Tokenを**段階的に統合・削減**
       - よりコンパクトで純粋な構成要素へと集約
    2. **Hard Assignment（離散的割当）**
       - 類似したトークン同士を曖昧に混ぜず、特定のパーツへ明確に統合
       - くっきりとしたパーツ分離を維持



# 提案手法：XTRAアーキテクチャ

- デュアルストリーム自己知識蒸留ネットワーク



# 実験結果：定量評価

| | SEPIN@1 | SEPIN@10 | SEPIN@100 | SEPIN@all |
|---|---|---|---|---|
| DINOv2 | $0.47 \pm 0.03$ | $0.39 \pm 0.02$ | $0.28 \pm 0.02$ | $0.11 \pm 0.01$ |
| DINOv2+ | $0.42 \pm 0.02$ | $0.35 \pm 0.03$ | $0.25 \pm 0.01$ | $0.13 \pm 0.01$ |
| XTRA | $3.95 \pm 0.12$ | $3.02 \pm 0.09$ | $1.54 \pm 0.06$ | $0.16 \pm 0.04$ |

ImageNet-1kにおける因子分離スコア

XTRAは高い因子分離能力を示す

| Method | Part mIoU (%) | vs. DINOv2 |
|---|---|---|
| DINOv2 | $42.3 \pm 0.4$ | baseline |
| DINOv2+ | $43.1 \pm 0.3$ | +0.8 |
| XTRA (no MVC) | $43.5 \pm 0.5$ | +1.2 |
| **XTRA (full)** | $\mathbf{46.8 \pm 0.3}$ | **+4.5** |

PartImageNet(人間がアノテーションしたデータセット)
におけるパーツセグメンテーション精度

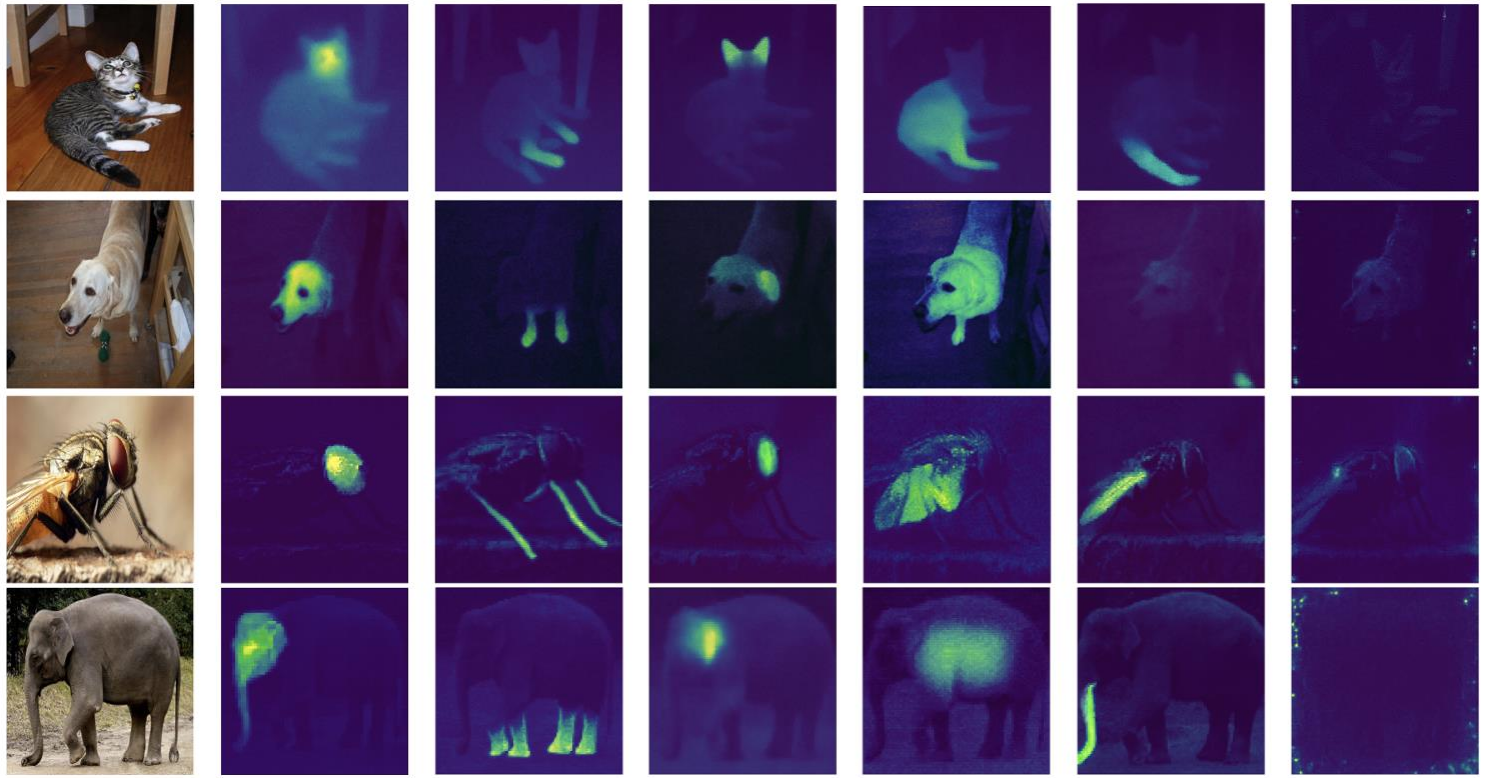
- XTRAはパーツ予測精度がDINOv2よりも高い
- MVCの有効性を実証

| | KNN | Linear |
|---|---|---|
| DINOv2 | 76.9 | 80.1 |
| DINOv2+ | 77.3 | 82.1 |
| XTRA (from scratch) | **81.9** | **83.8** |
| XTRA (pretrained on LVD142M) | **84.2** | **86.0** |

事前学習済みTeacherなしでの表現評価

TeacherなしでもXTRAはDINOv2を超え、
Teacherと組み合わせることで最高精度を達成

# 実験結果：定性評価



Factor Tokenの可視化

- **明確なパーツレベルの分離**
  - 特定部位にのみアテンションが集中
- **種を越えた意味的一貫性**
  - 四足歩行の動物だけでなく、形態が異なる昆虫であっても、同様にトークンが正しく割り当てられている

# 実験結果：下流タスク

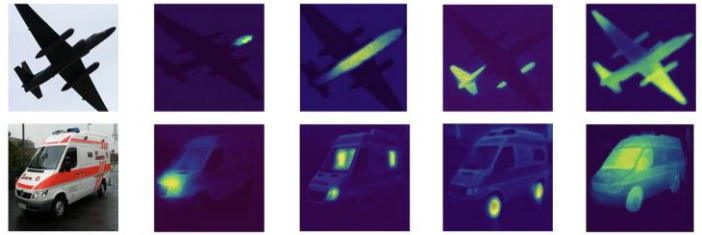
| モデル | 画像分類 | 領域分割 | 物体検出 |
|---|---|---|---|
| | Classification (Top-1) | Segmentation (mIoU) | Detection (AP box) |
| Backbone | ImageNet 1K | ADE20K | COCO2017 |
| MoCo-v3 | 83.1 | 47.3 | 47.9 |
| MAE | 83.6 | 48.1 | 50.3 |
| BEiT | 83.2 | 47.1 | 49.8 |
| iBOT | 84.0 | 50.0 | 48.2 |
| [illegible] | 82.8 | 51.3 | 46.8 |
| DINOv2 | 85.8 | 54.4 | 51.2 |
| DINOv2+ | 85.6 | 54.2 | 50.5 |
| XTRA | **85.9** | **55.1** | **52.1** |

提案手法：XTRAアーキテクチャ

**XTRAはパーツ分離能力だけでなく、**
**多様なタスクで従来手法を上回り、高い汎用表現力を実証**

# 失敗事例・限界

- **XTRAは乗り物における因子分離能力が低い**



乗り物カテゴリにおける因子トークンの可視化

  - **原因の考察**
    1. **クラス内パッチ特徴分散が低い**
       - 乗り物は金属面やガラスなど**見た目が滑らかで均一**

       → **全パッチが似通っているた**め、Factor Tokenを特定しづらい
    2. **事前学習データの偏りがある**
       - 車に特化した多様なデータセットで**追加学習を実施したところ、スコアが向上**

       → 事前学習データ(ImageNet)における**乗り物画像のアングルやパーツ変化の多様性不足**

| Category type | Within-class patch variance | XTRA SEPIN@1 |
|---|---|---|
| Animals (quadrupeds) | $0.43 \pm 0.06$ | 3.95 |
| Vehicles (cars, planes) | $0.18 \pm 0.04$ | 0.84 |

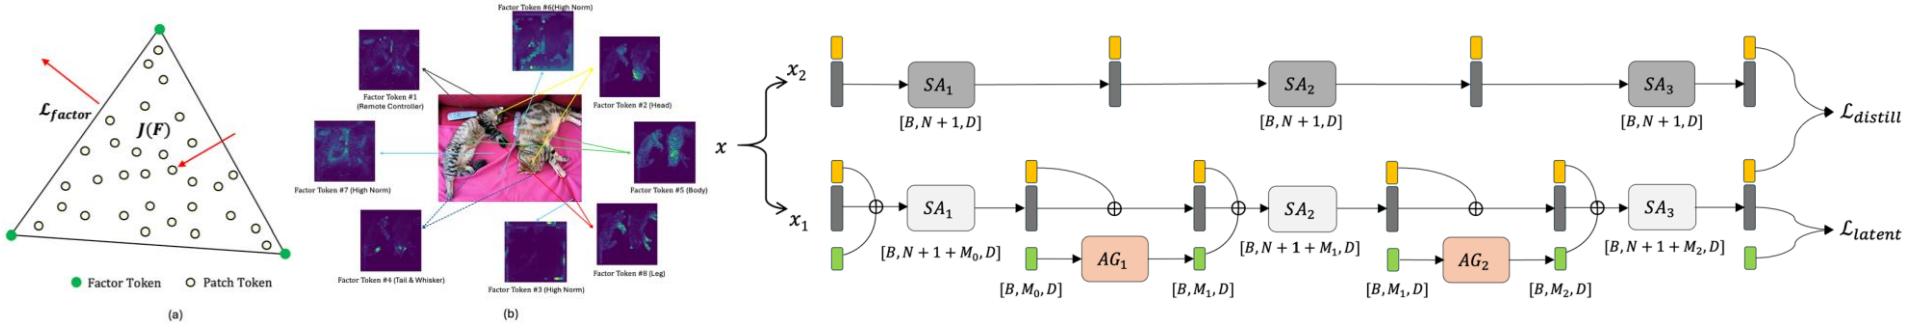
**カテゴリのパッチ特徴分散と因子分離度**

| Setting | Vehicle SEPIN@1 | Animal SEPIN@1 |
|---|---|---|
| XTRA (ImageNet pretrain only) | 0.84 | 3.95 |
| XTRA (+ Stanford Cars fine-tune) | 2.31 | 3.89 |

**Stanford Carsデータセットによる追加学習効果**

# The Extra Tokens Matter: Disentangled Representation Learning with Vision Transformers

Maofeng Tang, Hairong Qi, ICML, 2026






## どんなもの？

教師なしで画像を意味的なパーツ単位へと直交分解する表現学習フレームワーク**XTRA**を提案

## 先行研究と比べてどこがすごい？

**従来手法を凌駕する因子分離スコアを示しつつ、下流タスク精度やロバスト性も大幅に向上**

## 技術や手法のキモはどこ？

1. **幾何学的な線形混合モデル**
2. **Hard Assignmentを伴う多段階集約機構**

## どうやって有効だと検証した？

ImageNet-1Kでの**因子分解**指標やPartImageNetでの**パーツ分割**精度を通じて**明確な分解能力を立証**

## 議論はある？

- クラス内分散が低い剛体オブジェクトでの分離性能低下
- 因子の自動テキストラベル付け・生成モデルへの展開が未達成

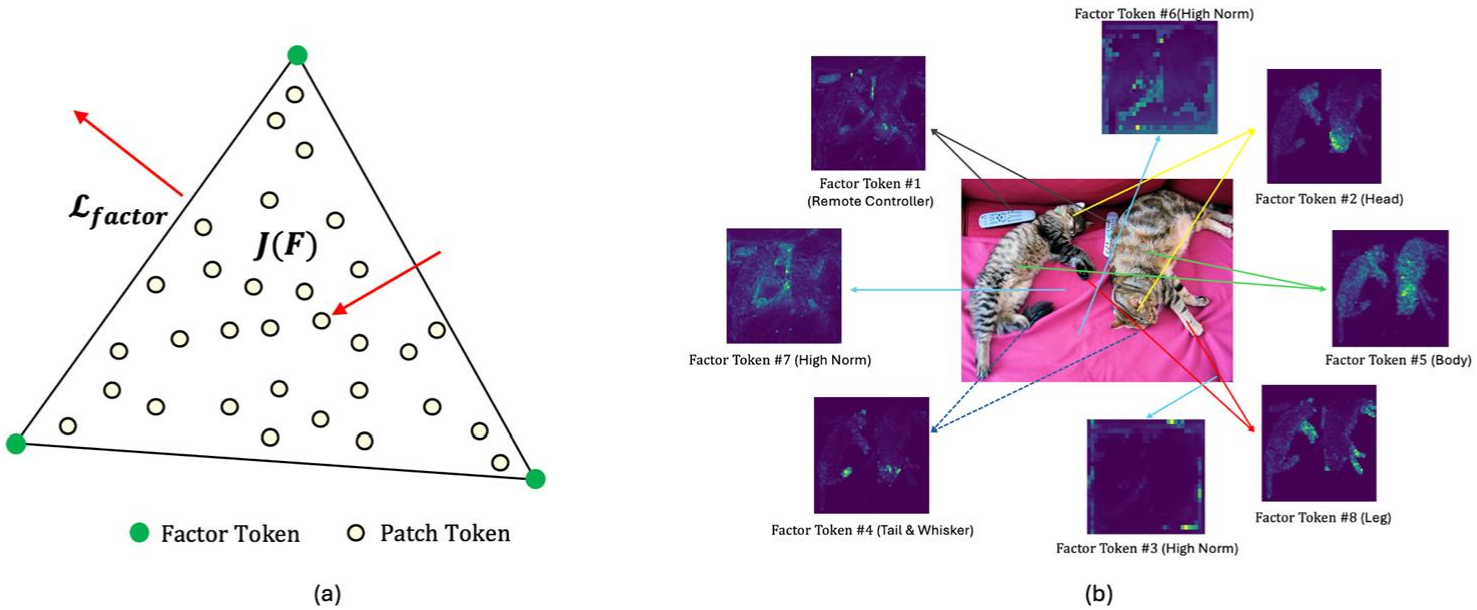



*Figure 1.* (a) Factor tokens in *latent* space: A geometric illustration of the two loss terms within the latent loss (Eq. 3) where the minimum volume constraint, $J(F)$, serves as the internal force pointing inward pushing the convex hull to its smallest volume; and the patch reconstruction constraint, $\mathcal{L}_{factor}$, serves as the external force pointing outward pulling the convex hull to encompass all patch tokens (or mixtures). (b) Factor tokens in *raw* space space: XTRA enables disentangled attention maps pertaining to consistent parts across multiple objects in the scene.

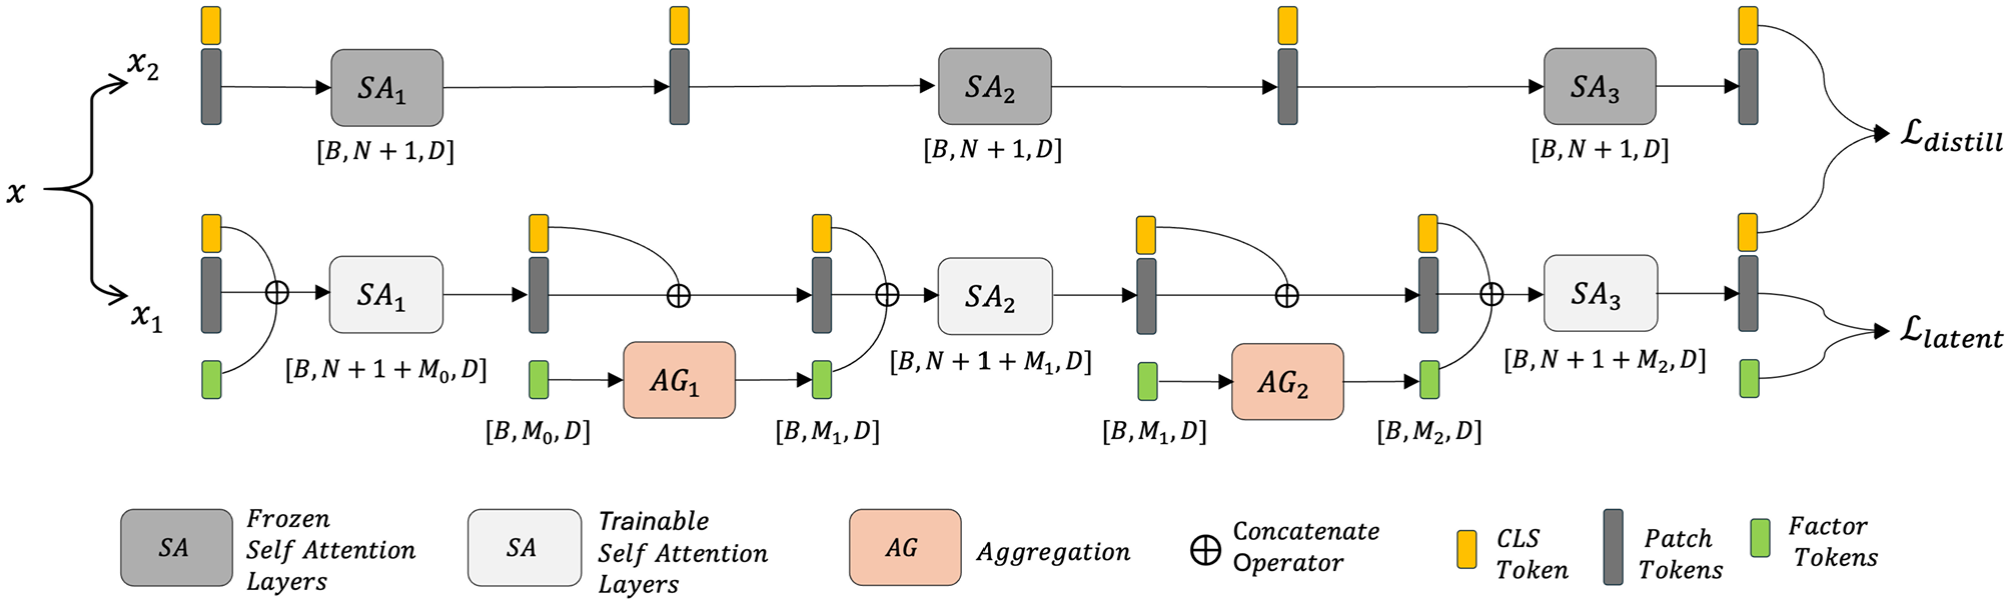



*Figure 2.* Illustration of XTRA built upon the dual-stream self-knowledge distillation network. Top: teacher network. Bottom: The multi-stage aggregation student network.

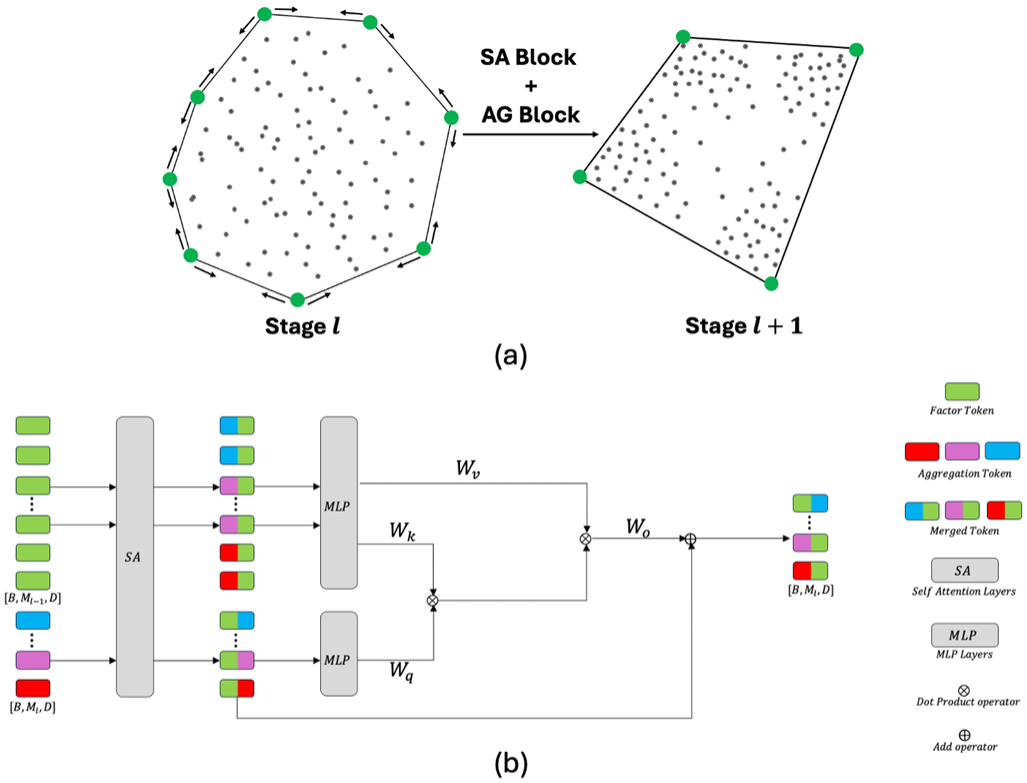



*Figure 3.* (a) Illustration of how the factor tokens and patch tokens evolve across two stages of aggregations. (b) Illustration of a 2-stage aggregation of factor tokens

*Table 1.* Representation disentanglement score with SEPIN@$k$ on ImageNet-1k, where $k$ denotes the top-$k$ dimensions (std from 3 Runs, higher is better).

| | SEPIN@1 | SEPIN@10 | SEPIN@100 | SEPIN@all |
|---|---|---|---|---|
| DINOv2 | $0.47 \pm 0.03$ | $0.39 \pm 0.02$ | $0.28 \pm 0.02$ | $0.11 \pm 0.01$ |
| DINOv2+ | $0.42 \pm 0.02$ | $0.35 \pm 0.03$ | $0.25 \pm 0.01$ | $0.13 \pm 0.01$ |
| XTRA | $3.95 \pm 0.12$ | $3.02 \pm 0.09$ | $1.54 \pm 0.06$ | $0.16 \pm 0.04$ |

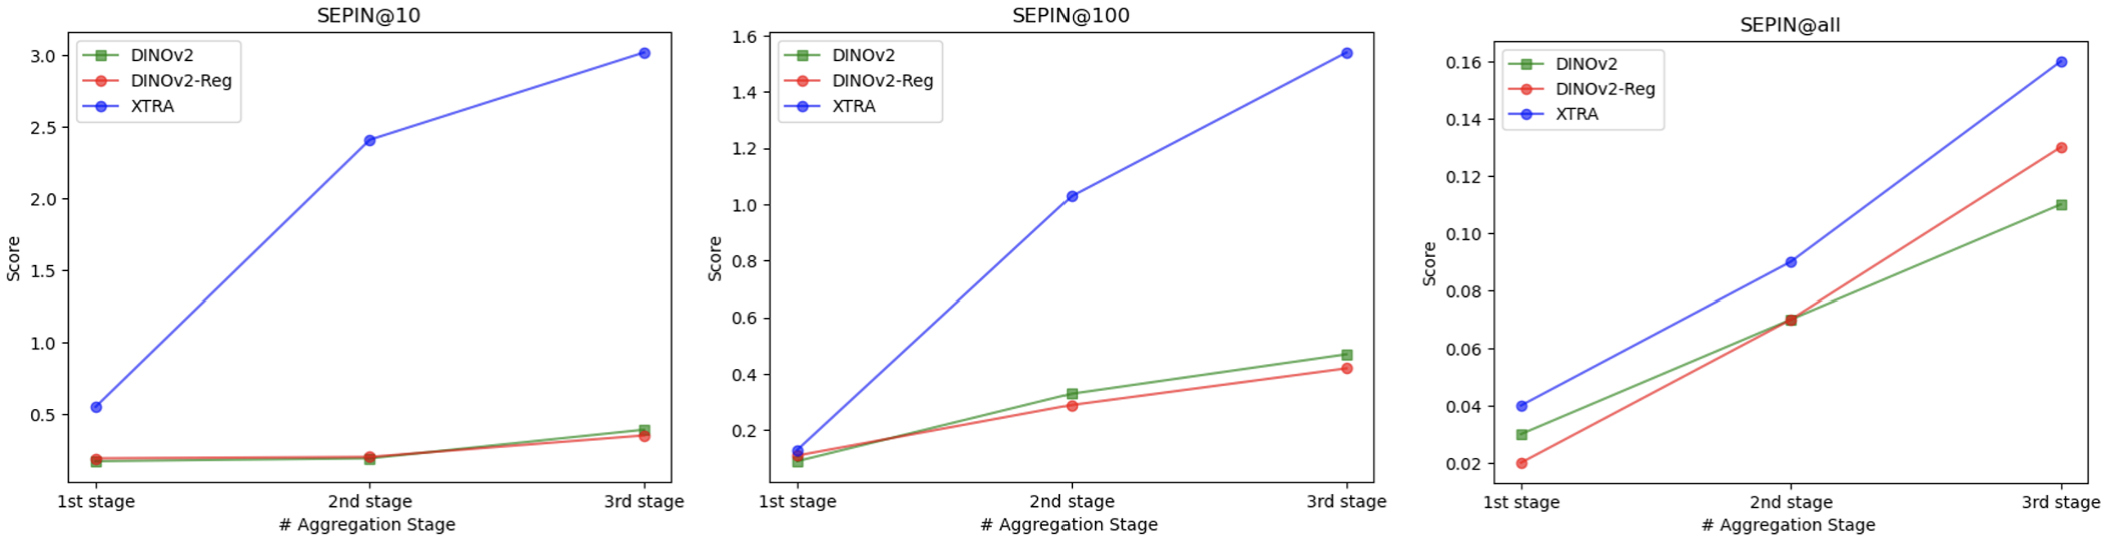



*Figure 4.* Evaluation of the disentanglement score at different aggregation stages in XTRA

*Table 2.* Part segmentation on PartImageNet. XTRA achieves superior part-level mIoU, with largest improvements on articulated parts (std from 3 Runs).

| **Method** | **Part mIoU (%)** | **vs. DINOv2** |
|---|---|---|
| DINOv2 | $42.3 \pm 0.4$ | baseline |
| DINOv2+ | $43.1 \pm 0.3$ | $+0.8$ |
| XTRA (no MVC) | $43.5 \pm 0.5$ | $+1.2$ |
| **XTRA (full)** | $\mathbf{46.8 \pm 0.3}$ | $\mathbf{+4.5}$ |

*Table 3.* Per-part breakdown for the "Quadruped" category. Largest improvements on articulated parts (legs, tail, ears)(%).

| **Method** | **Head** | **Body** | **Leg** | **Tail** | **Ear** | **Mean** |
|---|---|---|---|---|---|---|
| DINOv2 | 51.2 | 68.4 | 38.7 | 34.2 | 42.8 | 47.1 |
| XTRA | 56.8 | 71.3 | 45.2 | 41.6 | 48.9 | 52.8 |
| $\Delta$ | +5.6 | +2.9 | +6.5 | +7.4 | +6.1 | +5.7 |

*Table 4.* XTRA's robustness to distribution shifts.

| Method | ImageNet-C mCE ↓ | ImageNet-1K KNN ↑ |
|---|---|---|
| DINOv2 | 41.3 | 82.1 |
| DINOv2+ | 40.8 | 82.0 |
| XTRA | **38.2** | **84.2** |

*Table 5.* Evaluation of representation without pre-trained teacher network in KNN and Linear Probing on IN-1K(%).

| | Teacher | Backbone | KNN | Linear |
|---|---|---|---|---|
| DINOv2 | None (from scratch) | ViT-Base | 76.9 | 80.1 |
| DINOv2+ | None (from scratch) | ViT-Base | 77.3 | 82.1 |
| XTRA | DINOv2 (None, from scratch) | ViT-Base | **81.9** | **83.8** |
| XTRA | DINOv2 (LVD142M, pretrained) | ViT-Base | **84.2** | **86.0** |

*Table 6.* Ablation study of the effect of each module in XTRA (%)

| Frozen Teacher | Factors Rep | MVC | kNN | Linear Probing | SEPIN@1 |
|---|---|---|---|---|---|
| ○ | ○ | ○ | 76.1 | 78.2 | 0.41 |
| ✓ | ○ | ○ | 76.0 ↓ 0.1 | 79.2 ↑ 1.0 | 0.47 ↑ 0.06 |
| ✓ | ✓ | ○ | 72.4 ↓ 3.6 | 74.8 ↓ 4.4 | 0.51 ↑ 0.04 |
| ✓ | ○ | ✓ | 79.2 ↑ 6.8 | 82.9 ↑ 7.9 | 0.89 ↑ 0.38 |
| ✓ | ✓ | ✓ | **84.2** ↑ 4.0 | **86.0** ↑ 3.1 | **3.95** ↑ 3.06 |

*Table 7.* Ablation study on each component for part-level disentanglement (Soft: Softmax, Hard: Softmax + one-hot)

| **Configuration** | **SEPIN@1** | **KNN (%)** |
|---|---|---|
| Linear + No MVC + Soft | 0.51 | 13.9 |
| Linear + MVC + Soft | 1.52 | 79.8 |
| **Linear + MVC + Hard** | **3.95** | **84.2** |

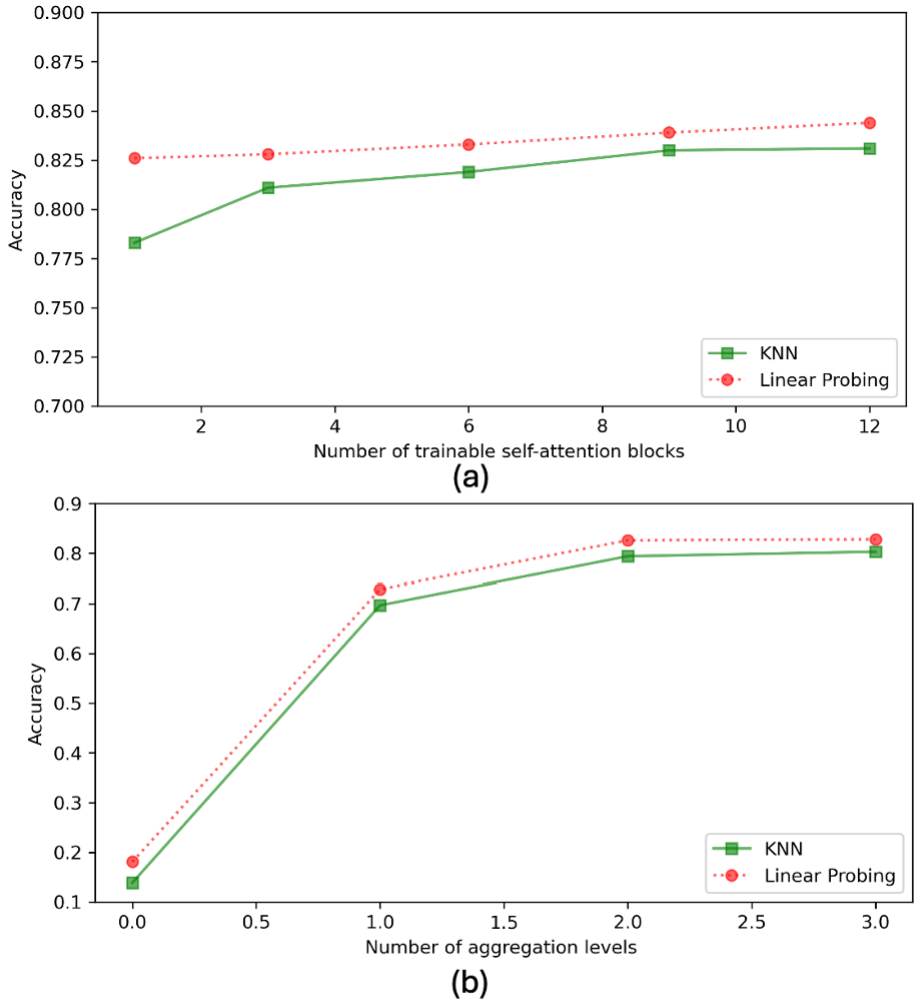



*Figure 5.* The effect of model complexity and aggregation. KNN & linear probing performance on (a) student networks of different numbers of trainable blocks and (b) different aggregation levels.

*Table 8.* XTRA generalizes across teachers. Gains scale with the semantic quality of the teacher's patch features.

| Teacher | Method | KNN ↑ | SEPIN@1 ↑ |
|---|---|---|---|
| MAE ViT-B (fixed) | MAE / XTRA | 65.2 / 68.4 | 0.29 / 1.94 |
| CLIP ViT-B/16 | CLIP / XTRA | 75.8 / 79.3 | 0.38 / 2.87 |
| DINOv2 LVD-142M | DINOv2 / XTRA | **82.1 / 84.2** | **0.47 / 3.95** |

*Table 9.* XTRA's token-level compositional structure (MVC) substantially outperforms dimension-level decorrelation (VICReg-L applied to patches).

| Method | KNN ↑ | SEPIN@1 ↑ | Part mIoU ↑ |
|---|---|---|---|
| DINOv2 | 82.1 | 0.47 | 42.3 |
| DINOv2 + VICReg | 83.1 | 0.89 | 43.8 |
| XTRA | **84.2** | **3.95** | **46.8** |