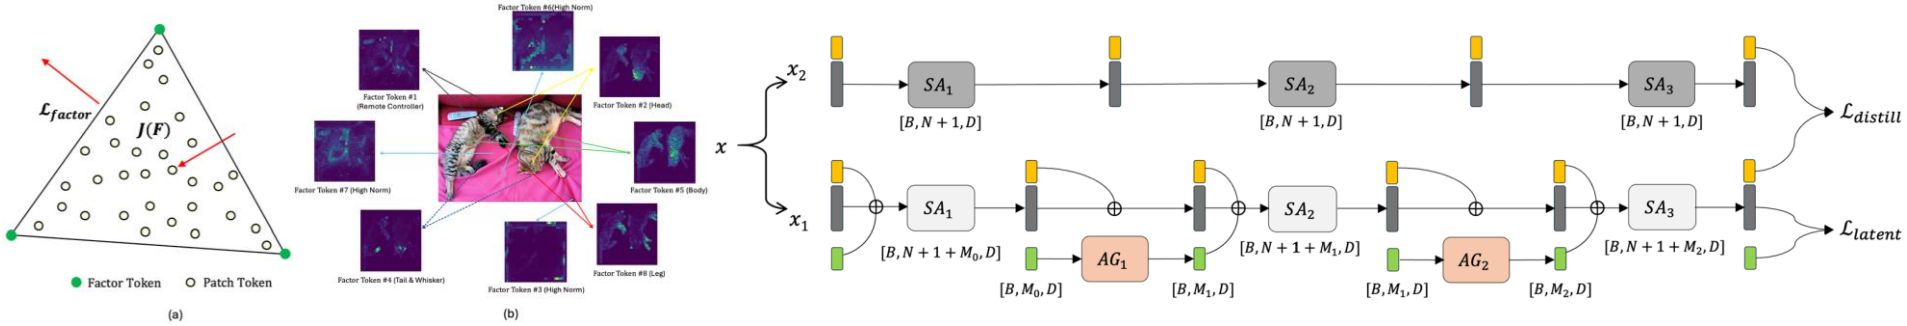
The Extra Tokens Matter: Disentangled Representation Learning with Vision Transformers

Maofeng Tang, Hairong Qi, ICML, 2026





どんなもの？

教師なしで画像を意味的なパーツ単位へと直交分解する表現学習フレームワーク**XTRA**を提案

先行研究と比べてどこがすごい？

従来手法よりも高い因子分離スコアを示しつつ
下流タスク精度やロバスト性も大幅に向上

技術や手法のキモはどこ？

1. **幾何学的な線形混合モデル**
2. **Hard Assignmentを伴う多段階集約機構**

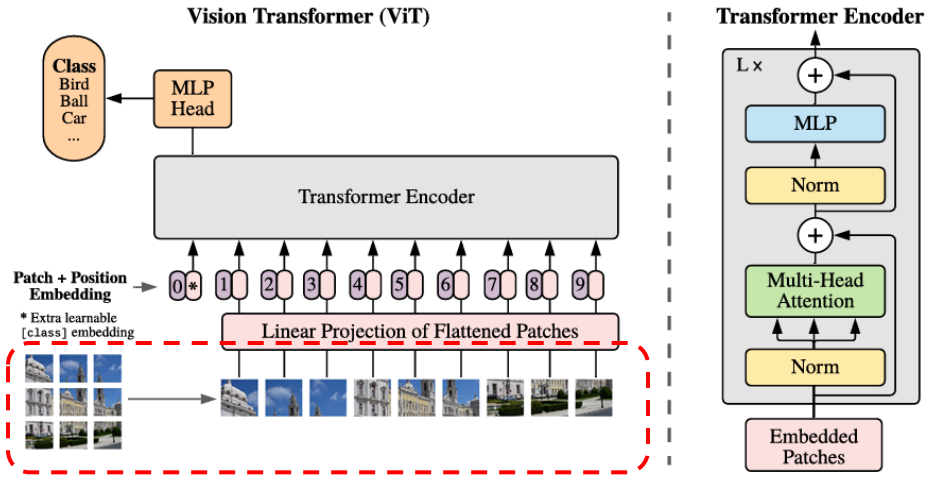
どうやって有効だと検証した？

ImageNet-1Kでの因子分解指標や
PartImageNetでのパーツ分割精度を通じて
明確な分解能力を立証

議論はある？

- クラス内分散が低い剛体オブジェクトでの分離性能低下
- 因子の自動テキストラベル付け・生成モデルへの展開が未達成

Vision Transformer



Vision Transformerのモデル概観

(Dosovitskiy et al., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", ICLR 2021, Fig. 1.)

・メカニズム

1. **パッチ分割**
   - 画像を固定サイズ(e.g. 16×16)のパッチへ分割しトークン化
2. **Self-Attention(自己注意機構)**
   - パッチトークン間の大域的な相互作用を計算し、画像内の空間的・意味的な位置関係を把握
3. **[CLS]トークン**
   - 最終的に画像全体の「大域的表現」を集約

➡ **画像タスクに対して高い精度**

背景・先行研究

- **従来のVision Transformer**
  - **Implicit & Entangled(暗黙的・もつれ)**
    - **大域的特徴抽出に優れている**
    - ピクセル単位でのみ反応
    - **パーツの境界が不明瞭**
    - **課題：背景やテクスチャへの過依存**

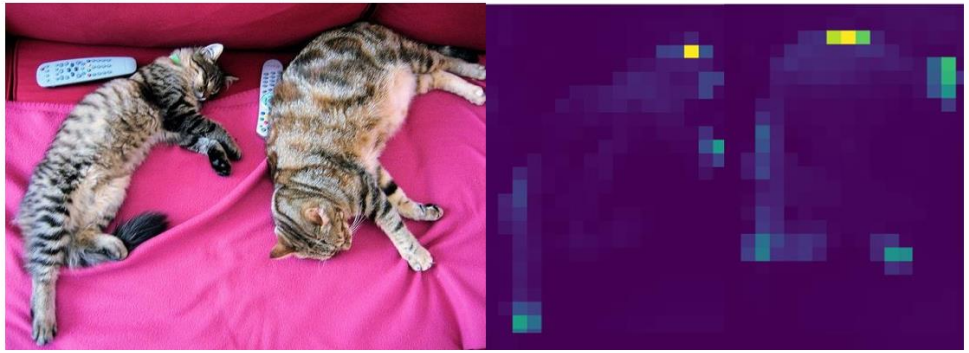


Figure.1a Vision transformer — global object representation

- **提案手法 XTRA**
  - **Explicit & Disentangled(明示的・分離)**
    - **教師なしで「頭」「足」「体」といった意味的まとまりで分離**
    - **ゼロショットでのパーツ認識や解釈性・ロバスト性の向上**

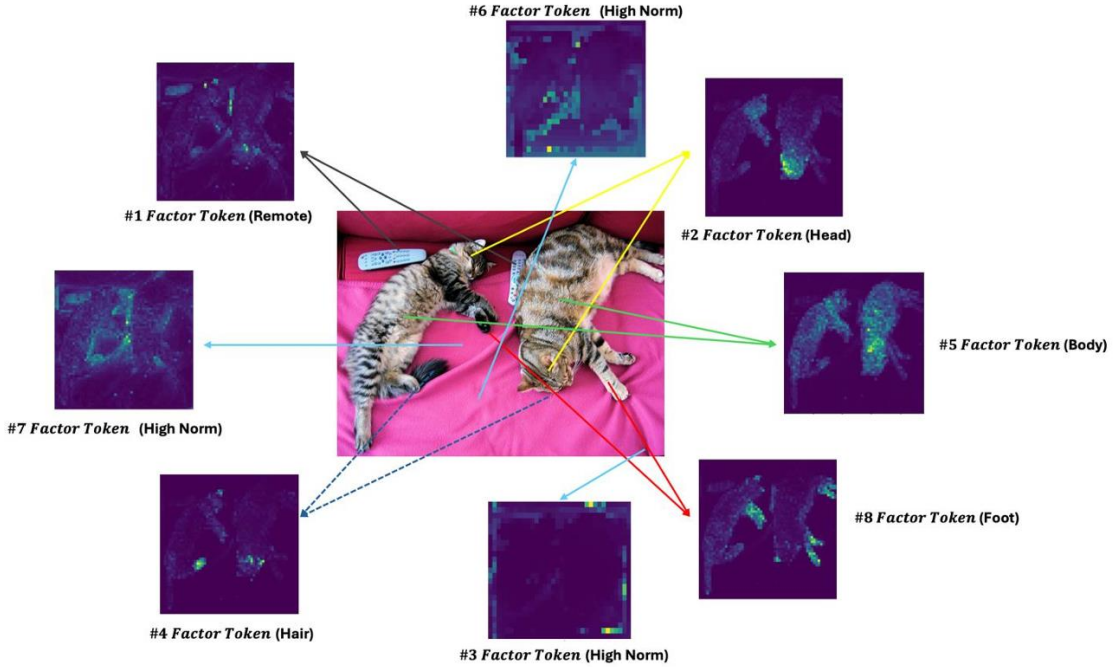


Figure.1b XTRA — explicit semantic parts

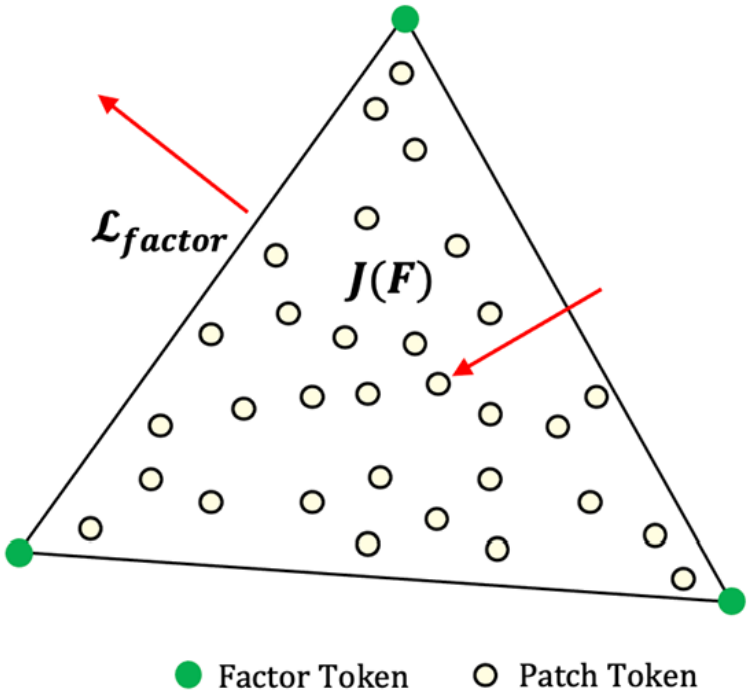
提案手法：XTRA (eXtra Token-based RepresentAtion learning)

- **潜在空間における線形混合モデル**（Linear Mixing Model）

  - **仮説：パッチトークンは意味的要因の凸結合として表される**

$$p_i = F \cdot w_i + \varepsilon_i$$

  - p_i：パッチトークン(観測データ)
  - F：Factor Tokenセット
  - w_i：混合比率(重み)
  - ε_i ：ノイズ



提案手法：MVC（Minimum Volume Constraint）

- **最小体積制約(MVC)によるFactor Tokenの特定**
  - 潜在損失

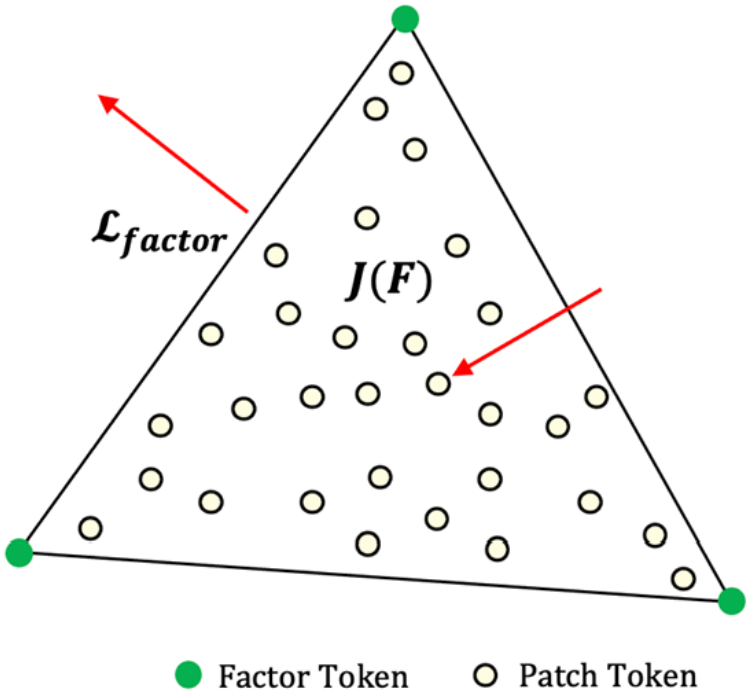
$$L_{latent} = \lambda_{latent} L_{factor} + \lambda_{volume} J(F)$$

1. L_{factor}：**再構成損失**
   - **外向きの引力**：全パッチを包み込む制約

$$L_{factor} = \frac{1}{2} log(\sum_{i=1}^{N} ||p_i - Fw_i||^2)$$

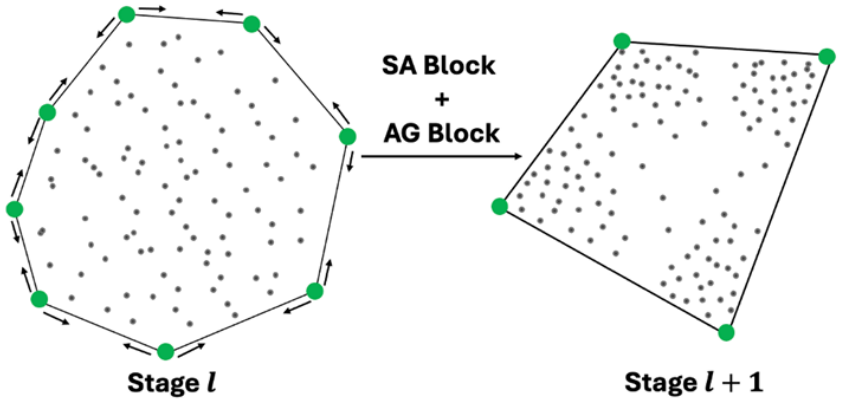
2. $J(F)$：**MVC**
   - **内向きの圧力**：凸包の体積を最小化する制約(直交化)

$$J(F) = ||F^T F - I||_F^2$$



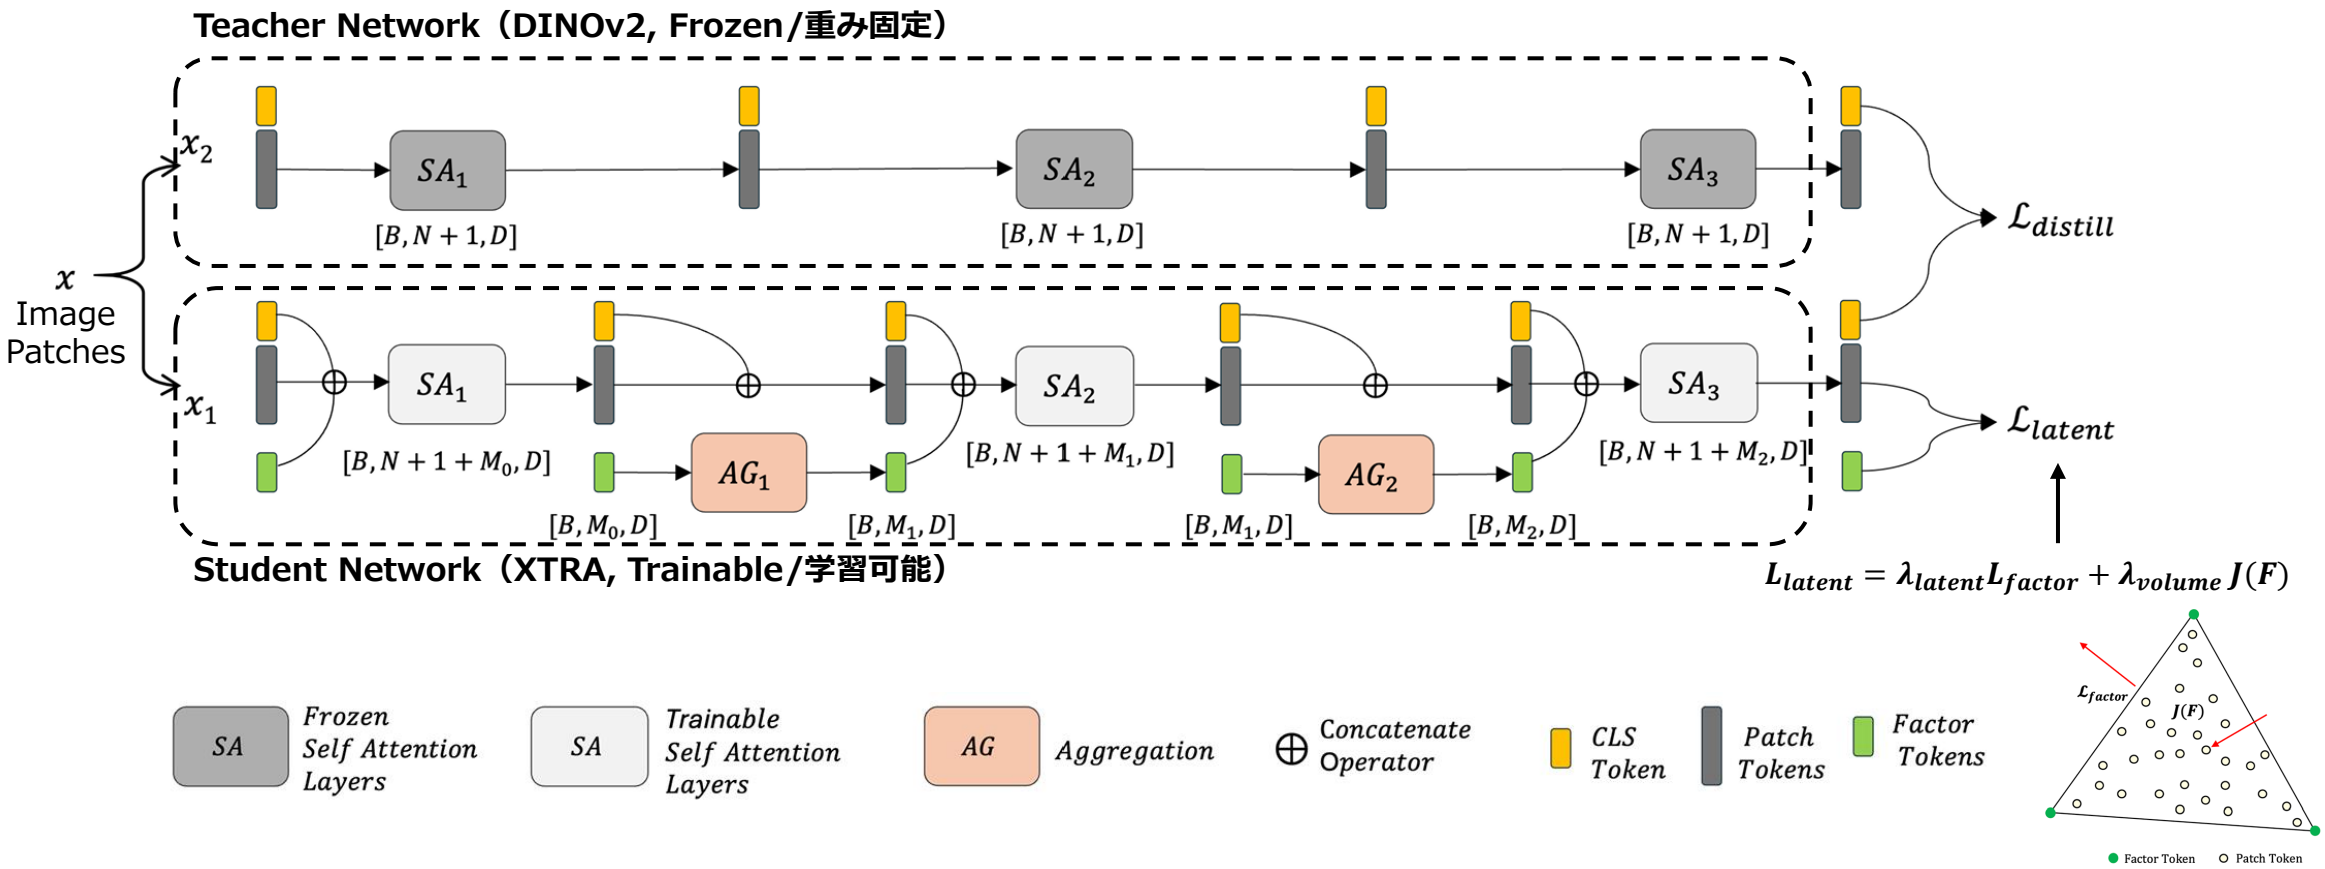
提案手法：Multi-Stage Aggregation Block

- **Factor Tokenの集約メカニズム**
  - **課題**
    - 層を深くしていくとFactor Token同士が似通ってしまう（**Over-smoothing**）
  - **手法**
    1. **Aggregation Block（集約ブロック）**
       - 層が深くなるにつれて類似するFactor Tokenを**段階的に統合・削減**
       - よりコンパクトで純粋な構成要素へと集約
    2. **Hard Assignment（離散的割当）**
       - 類似したトークン同士を曖昧に混ぜず、特定のパーツへ明確に統合
       - くっきりとしたパーツ分離を維持



提案手法：XTRAアーキテクチャ

- デュアルストリーム自己知識蒸留ネットワーク



実験結果：定量評価

	SEPIN@1	SEPIN@10	SEPIN@100	SEPIN@all
DINOv2	0.47 ± 0.03	0.39 ± 0.02	0.28 ± 0.02	0.11 ± 0.01
DINOv2+	0.42 ± 0.02	0.35 ± 0.03	0.25 ± 0.01	0.13 ± 0.01
XTRA	3.95 ± 0.12	3.02 ± 0.09	1.54 ± 0.06	0.16 ± 0.04

ImageNet-1kにおける因子分離スコア

XTRAは高い因子分離能力を示す

Method	Part mIoU (%)	vs. DINOv2
DINOv2	42.3 ± 0.4	baseline
DINOv2+	43.1 ± 0.3	+0.8
XTRA (no MVC)	43.5 ± 0.5	+1.2
XTRA (full)	$\mathbf{46.8 \pm 0.3}$	**+4.5**

PartImageNet(人間がアノテーションしたデータセット)
におけるパーツセグメンテーション精度

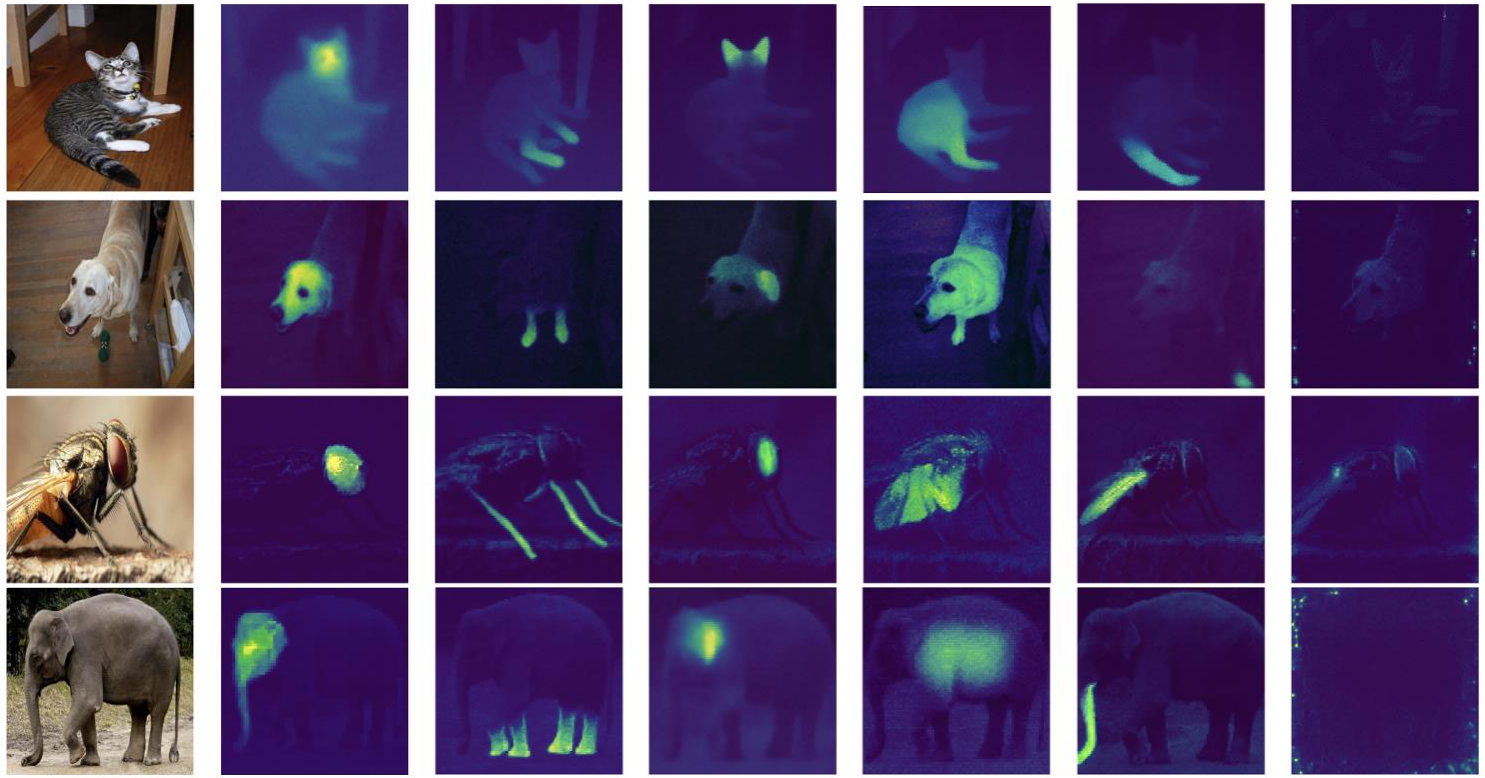
- XTRAはパーツ予測精度がDINOv2よりも高い
- MVCの有効性を実証

	KNN	Linear
DINOv2	76.9	80.1
DINOv2+	77.3	82.1
XTRA (from scratch)	**81.9**	**83.8**
XTRA (pretrained on LVD142M)	**84.2**	**86.0**

事前学習済みTeacherなしでの表現評価

TeacherなしでもXTRAはDINOv2を超え、
Teacherと組み合わせることで最高精度を達成

実験結果：定性評価



Factor Tokenの可視化

- **明確なパーツレベルの分離**
  - 特定部位にのみアテンションが集中
- **種を越えた意味的一貫性**
  - 四足歩行の動物だけでなく、形態が異なる昆虫であっても、同様にトークンが正しく割り当てられている

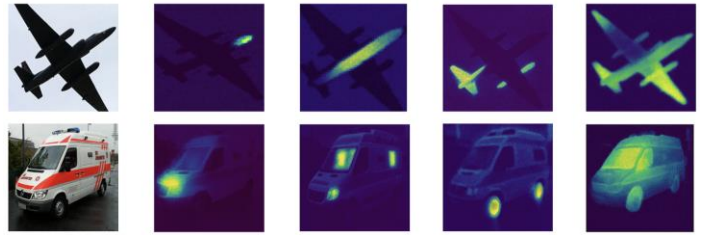
実験結果：下流タスク

モデル	画像分類	領域分割	物体検出
	Classification (Top-1)	Segmentation (mIoU)	Detection (AP box)
Backbone	ImageNet 1K	ADE20K	COCO2017
MoCo-v3	83.1	47.3	47.9
MAE	83.6	48.1	50.3
BEiT	83.2	47.1	49.8
iBOT	84.0	50.0	48.2
DINO v1	82.8	51.3	46.8
DINOv2	85.8	54.4	51.2
DINOv2+	85.6	54.2	50.5
XTRA	**85.9**	**55.1**	**52.1**

XTRAはパーツ分離能力だけでなく、
多様なタスクで従来手法を上回り、高い汎用表現力を実証

失敗事例・限界

- **XTRAは乗り物における因子分離能力が低い**



乗り物カテゴリにおける因子トークンの可視化

  - **原因の考察**
    1. **クラス内パッチ特徴分散が低い**
       - 乗り物は金属面やガラスなど**見た目が滑らかで均一**

       → **全パッチが似通っているた**め、Factor Tokenを特定しづらい
    2. **事前学習データの偏りがある**
       - 車に特化した多様なデータセットで**追加学習を実施したところ、スコアが向上**

       → 事前学習データ(ImageNet)における**乗り物画像のアングルやパーツ変化の多様性不足**

Category type	Within-class patch variance	XTRA SEPIN@1
Animals (quadrupeds)	0.43 ± 0.06	3.95
Vehicles (cars, planes)	0.18 ± 0.04	0.84

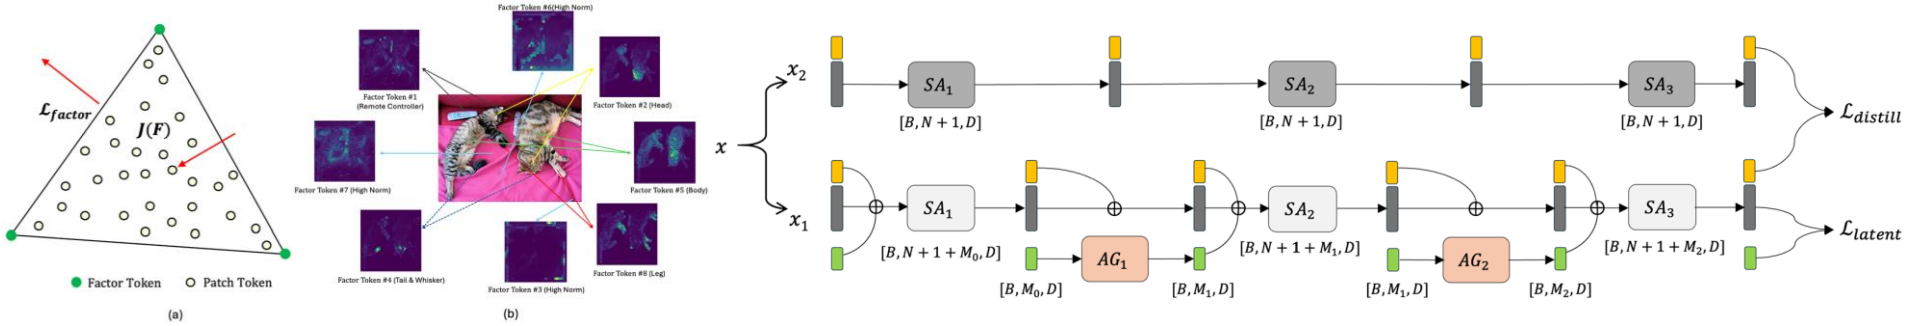
カテゴリのパッチ特徴分散と因子分離度

Setting	Vehicle SEPIN@1	Animal SEPIN@1
XTRA (ImageNet pretrain only)	0.84	3.95
XTRA (+ Stanford Cars fine-tune)	2.31	3.89

Stanford Carsデータセットによる追加学習効果

The Extra Tokens Matter: Disentangled Representation Learning with Vision Transformers

Maofeng Tang, Hairong Qi, ICML, 2026





どんなもの？

教師なしで画像を意味的なパーツ単位へと直交分解する表現学習フレームワーク**XTRA**を提案

先行研究と比べてどこがすごい？

従来手法よりも高い因子分離スコアを示しつつ
下流タスク精度やロバスト性も大幅に向上

技術や手法のキモはどこ？

1. **幾何学的な線形混合モデル**
2. **Hard Assignmentを伴う多段階集約機構**

どうやって有効だと検証した？

ImageNet-1Kでの因子分解指標や
PartImageNetでのパーツ分割精度を通じて
明確な分解能力を立証

議論はある？

- クラス内分散が低い剛体オブジェクトでの分離性能低下
- 因子の自動テキストラベル付け・生成モデルへの展開が未達成